

UNIVERSIDAD POLITÉCNICA DE MADRID

E.T.S. DE INGENIERÍA DE SISTEMAS INFORMÁTICOS

PROYECTO FIN DE GRADO

GRADO EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

LoRA para control de modos musicales en ACE-Step 1.5

Desarrollado por: Ignacio Franco Almendárez

Dirigido por: Francisco Serradilla

Madrid, 17 de junio de 2026



LoRA para control de modos musicales en ACE-Step 1.5

Desarrollado por: Ignacio Franco Almendárez

Dirigido por: Francisco Serradilla

Proyecto Fin de Grado, 17 de junio de 2026

E.T.S. de Ingeniería de Sistemas Informáticos

Campus Sur UPM, Carretera de Valencia (A-3), km. 7

28031, Madrid, España

Esta obra está bajo una licencia [Creative Commons](#) «Atribución-NoComercial-CompartirIgual 4.0 Internacional». Obra derivada de <https://github.com/blazaid/UPM-Report-Template>.



Todo cambio respecto a la obra original es responsabilidad exclusiva del presente autor.

Agradecimientos

Este proyecto nace de la confluencia de dos de los factores más relevantes en mi vida: la música y la ciencia. Desde el principio quise apostar por un trabajo que me permitiera explorar ambos mundos, y la generación musical mediante inteligencia artificial me pareció un terreno fascinante para hacerlo.

De alguna forma, este proyecto me ha mantenido unido a mi mayor pasión incluso en los momentos más complicados. Salgo de él con más ganas que nunca de seguir tocando, habiendo aprendido a valorar la música de otra manera: a entender relaciones más sutiles entre armonías y a disfrutarla con mayor profundidad.

Muchos pensarán que la generación musical va en contra de los artistas; personalmente creo que es una herramienta poderosa para acercar el conocimiento musical a personas de todo el mundo y facilitar la evolución creativa de cada individuo. Quien quiera ser artista seguirá teniendo sus ideas; quien quiera aprender música podrá hacerlo de una forma más rápida y accesible. Y el directo, esa parte fundamental e irremplazable, siempre seguirá siendo nuestra.

Por todo ello, quiero dar las gracias a mi familia, a mis amigos, a mi pareja y a mis compañeros de carrera por acompañarme en este capítulo y hacerlo más llevadero. También a quienes comparten escenario conmigo, por recordarme cada vez que cojo la guitarra que esa parte irremplazable sigue bien viva. Por último, y no por ello menos importante, agradezco a mi tutor su orientación a lo largo del desarrollo del proyecto y el acceso a los recursos necesarios para llevar a cabo todas las pruebas y experimentos. Asimismo, gracias a Ángel Paz, doctorando en música, por su guía en los aspectos de teoría musical relacionados con el trabajo.

Resumen

Este trabajo estudia la adaptación del modelo generativo musical ACE-Step 1.5 mediante técnicas LoRA (*Low-Rank Adaptation*) para incorporar control modal explícito durante la generación. El objetivo principal es mejorar la capacidad del modelo para producir música coherente en los siete modos diatónicos (jónico, dórico, frigio, lidio, mixolidio, eólico y locrio), manteniendo la calidad musical general del modelo base.

Para ello se construyó un conjunto de datos propio de 102 fragmentos musicales (20–50 segundos), obtenidos a partir de canciones existentes y etiquetados por modo. La metodología combina entrenamiento LoRA sobre ACE-Step con una búsqueda sistemática de hiperparámetros mediante inferencia por lotes. La evaluación se realiza en dos fases: un cribado automático determinista y, sobre los candidatos resultantes, una evaluación perceptual audio a audio con apoyo instrumental (guitarra), aplicando una rúbrica de centro tonal, color modal, no modulación y coherencia. La evaluación manual resulta especialmente relevante en un dominio donde las métricas automáticas existentes son insuficientes para juzgar el carácter modal.

Los resultados muestran control modal parcial: el modelo aprende de forma robusta los modos mayores, mientras que los modos menores –y en particular el locrio– siguen presentando un sesgo sistemático del modelo base hacia sonoridades mayores. La búsqueda de hiperparámetros identifica la tasa de aprendizaje como factor dominante, y un experimento de confirmación con la configuración óptima reduce de forma específica el sesgo en modo dórico. Se concluye que LoRA es una estrategia viable para añadir condicionamiento modal sin reentrenar el modelo completo, aunque la separabilidad en modos menores queda como limitación abierta.

Palabras clave: Generación musical; ACE-Step 1.5; LoRA; Control modal; Fine-tuning

Abstract

This project investigates the adaptation of the ACE-Step 1.5 music generation model using LoRA (*Low-Rank Adaptation*) to introduce explicit modal control during generation. The main goal is to improve the model’s ability to generate coherent music in the seven diatonic modes (Ionian, Dorian, Phrygian, Lydian, Mixolydian, Aeolian, and Locrian) while preserving the overall musical quality of the base model.

A custom dataset of 102 musical clips (20–50 seconds) was built from existing songs and labeled by mode. The methodology combines LoRA training on ACE-Step with a systematic hyperparameter search through batch inference. Evaluation is carried out in two stages: an automatic deterministic ranking and, on the resulting candidates, a perceptual evaluation conducted clip by clip with instrumental support (guitar), applying a rubric based on tonal center, modal color, non-modulation, and coherence. Manual evaluation is particularly relevant in a domain where existing automatic metrics are insufficient to judge modal character.

Results show partial modal control: the model robustly learns the major modes, whereas the minor modes –and especially Locrian– still exhibit a systematic bias of the base model towards major tonalities. The hyperparameter search identifies the learning rate as the dominant factor, and a confirmation experiment with the optimal configuration specifically reduces the bias in Dorian mode. The study concludes that LoRA is a viable strategy for adding modal conditioning without full model retraining, although separability in minor modes remains an open limitation.

Keywords: Music Generation; ACE-Step 1.5; LoRA; Modal Control; Fine-tuning

Índice general

1	Introducción	1
1.1	Objetivos	1
1.2	Motivación	2
1.3	Justificación	2
1.4	Preguntas de investigación y alcance	2
1.5	Contribuciones del trabajo	3
1.6	Estructura de la memoria	4
2	Estado de la cuestión	5
2.1	Generación musical con modelos generativos	5
2.2	ACE-Step como base de trabajo	5
2.3	Panorama actual de modelos de generación musical	6
2.4	Funcionamiento conceptual de ACE-Step y del ajuste LoRA	7
2.5	Los modos diatónicos	8
2.6	Control modal y dificultad del problema	13
2.7	Síntesis del estado de la cuestión y hueco identificado	13
2.8	Posicionamiento del trabajo respecto al estado actual	14
3	Metodología	15
3.1	Entorno y recursos	15

3.2	Construcción del dataset	16
3.3	Entrenamiento LoRA	17
3.4	Búsqueda sistemática de hiperparámetros	23
3.5	Pruebas exploratorias no válidas y decisiones de descarte	23
3.6	Pipeline de inferencia y selección de checkpoints	24
3.7	Implementación técnica del pipeline experimental	25
3.8	Métricas automáticas y criterios de decisión	26
3.9	Evaluación manual	28
4	Resultados y discusión	30
4.1	Resumen de resultados actuales	30
4.2	Resultados automáticos de la fase de validación	30
4.3	Resultados de la búsqueda sistemática de hiperparámetros	31
4.4	Evaluación manual de la búsqueda de hiperparámetros	35
4.5	Experimento de confirmación	37
4.6	Análisis cualitativo por modo	38
4.7	Análisis por modo del checkpoint de referencia run_D	40
4.8	Análisis de tasas de éxito por umbral	40
4.9	Patrón de confusión mayor/menor	44
4.10	Ablación de variantes de prompt	45
4.11	Comparativa global de configuraciones	46
4.12	Hallazgos principales	47
4.13	Respuesta a las preguntas de investigación	48

Índice general	III
4.14 Validez y limitaciones	48
5 Conclusiones y trabajo futuro	50
5.1 Conclusiones	50
5.2 Trabajo futuro	51
A Resultados completos de la búsqueda de hiperparámetros	52
B Rankings completos por tasa de éxito	54
C Impacto social y medioambiental	58
C.1 Impacto social	58
C.2 Impacto medioambiental	60
Glosario	64
Siglas	64

Índice de figuras

2.1	Arquitectura de ACE-Step 1.5. Los bloques marcados con <i>snowflake</i> (Qwen3, VAE) permanecen congelados en todos los escenarios. Los marcados con <i>llama</i> son entrenables en fine-tuning completo. Con LoRA, todo el modelo queda congelado y solo se añaden matrices de bajo rango en <code>q_proj</code> , <code>k_proj</code> , <code>v_proj</code> y <code>o_proj</code> de la Cross Attention del DiT.	8
2.2	Escala de Do mayor sobre un teclado de piano. Las teclas azules son las siete notas de la escala; la tónica (Do) aparece en azul oscuro. Las marcas T (verde) y S (rojo) indican la distancia entre notas consecutivas de la escala.	9
2.3	Los siete modos diatónicos derivados de la escala de Do mayor. Cada fila comienza en una nota distinta; el patrón T/S resultante cambia en cada modo. La celda naranja señala la nota característica de cada modo, es decir, la nota que lo diferencia armónicamente del mayor o del menor natural.	10
2.4	Comparativa entre Do jónico y Re dórico. Ambos modos utilizan exactamente las mismas siete notas (las teclas blancas del piano), pero al tomar Raíz distinta, el patrón de intervalos cambia: el semitono cae en distinto lugar sobre la tónica, lo que determina el carácter del modo. La nota característica del dórico (Si, naranja) es la que lo distingue del menor natural.	12
3.1	Interfaz de entrenamiento LoRA de ACE-Step 1.5. Los paneles permiten seleccionar el dataset de tensores, configurar los hiperparámetros LoRA y los parámetros generales del entrenamiento, y especificar el directorio de salida de checkpoints.	18
3.2	Ejemplo de vector de chroma para Re dórico (valores simulados). Cada barra representa la energía relativa de una clase de altura; la tónica (D, rojo) domina, las demás notas diatónicas (azul) concentran la mayor parte de la energía restante, y las notas no diatónicas (gris) presentan valores muy bajos. La línea de puntos indica la plantilla binaria diatónica utilizada en la métrica s_m . La 6ª mayor (Si) es la nota característica que distingue al dórico del eólico.	27

4.1	Los 24 experimentos de la búsqueda de hiperparámetros ordenados por <code>auto_score_0_1</code> . En azul, los experimentos con $lr = 10^{-4}$; en rojo, los de $lr = 10^{-3}$. La línea discontinua marca el punto de corte entre ambos grupos. El experimento 19 (rayado) presenta duración anómala. Los 12 experimentos con $lr = 10^{-4}$ ocupan las 12 primeras posiciones sin excepción.	32
4.2	Mapa de calor de <code>auto_score_0_1</code> en función de rank y alpha (media sobre lr y dropout). Los valores más altos se concentran en $\alpha = 32$ independientemente del rank.	33
4.3	Sensibilidad de <code>auto_score_0_1</code> a la tasa de aprendizaje. La diferencia entre 10^{-4} y 10^{-3} es la mayor observada entre todos los hiperparámetros explorados.	34
4.4	Sensibilidad de <code>auto_score_0_1</code> al parámetro alpha. $\alpha = 32$ supera consistentemente a $\alpha = 128$, especialmente en combinación con $lr = 10^{-4}$	34
4.5	Posición de los cinco experimentos mejor puntuados automáticamente en el ranking automático (azul oscuro) y en el ranking de evaluación manual (azul claro). La barra más corta indica mejor posición (1 = mejor). Exp_01 lidera el ranking automático pero queda último en el manual; Exp_18 ocupa la cuarta posición automática pero la primera en escucha informada. Se incluyen los valores reales de <code>auto_score_0_1</code> y la puntuación manual para referencia.	36
4.6	Comparativa de la evaluación manual por modo entre run_D y el experimento de confirmación. Las barras representan el porcentaje del máximo de 20 puntos. La línea discontinua marca el promedio global de run_D (62 %). El modo dórico (naranja) es el único con mejora significativa (+12 pp); el resto retrocede entre 5 y 23 puntos porcentuales.	38
4.7	Top 10 de configuraciones por porcentaje de audios que superan el umbral en color modal . Se muestran lado a lado el umbral permisivo (≥ 2) y el estricto (≥ 3).	42
4.8	Mapa de calor del porcentaje de éxito estricto (≥ 3 en criterios 1–5; ≥ 12 en total 0–20) para las diez configuraciones con mejor promedio. Cada columna corresponde a un criterio de la rúbrica más el total agregado.	43
B.1	Top 10 de configuraciones por porcentaje de éxito en centro tonal	54
B.2	Top 10 de configuraciones por porcentaje de éxito en no modulación	55

B.3	Top 10 de configuraciones por porcentaje de éxito en coherencia musical	56
B.4	Top 10 de configuraciones por porcentaje de audios que superan el umbral en total agregado (umbrales permisivo $\geq 10/20$ y estricto $\geq 12/20$).	57

Índice de tablas

2.1	Caracterización de los siete modos diatónicos con ejemplos de música popular .	11
2.2	Posicionamiento del trabajo respecto a enfoques habituales	14
3.1	Distribución de clips por modo en el dataset	16
3.2	Parámetros configurables en la interfaz de entrenamiento LoRA	19
3.3	Configuración completa del entrenamiento run_D	22
3.4	Rejilla de hiperparámetros de la búsqueda sistemática (24 configuraciones) . .	23
3.5	Scripts del pipeline experimental y su función	25
3.6	Rúbrica de evaluación manual (escala 1–5 por criterio, máximo 20 puntos) . . .	29
4.1	Resumen de resultados automáticos recientes	30
4.2	Top 10 configuraciones de la búsqueda de hiperparámetros por auto_score_0_1	31
4.3	Sensibilidad de auto_score_0_1 a cada hiperparámetro	33
4.4	Resultados de la evaluación manual de la búsqueda de hiperparámetros (escala 0–20, 4 criterios)	35
4.5	Comparativa directa entre run_D y el experimento de confirmación (epoch 140, escala 0–20)	37
4.6	Media por modo en el checkpoint de referencia run_D ($r = 64$, $\alpha = 128$, $lr = 5 \cdot 10^{-5}$, epoch 100)	40
4.7	Confusiones recurrentes entre modo objetivo y modo generado	45
4.8	Comparativa de variantes de prompt sobre el mismo checkpoint (epoch 100) . .	46

4.9	Comparativa resumida de configuraciones LoRA evaluadas	47
A.1	Resultados completos de la búsqueda de hiperparámetros (24 experimentos, epoch 140)	53
C.1	Objetivos de Desarrollo Sostenible relacionados con el proyecto	58
C.2	Estimación del tiempo de uso de GPU durante el proyecto	61

La generación musical mediante [IA](#) ha alcanzado un nivel de calidad sonora notable en los últimos años. Sin embargo, en contextos de composición asistida no basta con generar audio plausible: también es necesario controlar propiedades musicales concretas para dirigir la salida hacia una intención armónica definida. Una de esas propiedades es la modalidad.

Este [PFG](#) se centra en añadir control modal a un modelo generativo que ya funciona bien a nivel tímbrico y estructural, evitando reentrenamientos completos de alto coste. La estrategia elegida es el fine-tuning eficiente mediante [LoRA](#) sobre [ACE-Step](#), de forma que el modelo pueda responder mejor a condicionamiento por modo sin degradar la musicalidad general aprendida.

El trabajo incluye una primera fase exploratoria sobre ACE-Step 1.3 y una fase principal sobre ACE-Step 1.5. Esta transición permitió estabilizar el flujo de entrenamiento e inferencia, mejorar la repetibilidad experimental y obtener resultados superiores a los iniciales.

1.1. Objetivos

El objetivo general del proyecto es incorporar control modal explícito en un modelo generativo musical de propósito general, preservando la calidad percibida del audio y mejorando su utilidad en escenarios de composición asistida.

Como objetivos específicos se definen los siguientes:

1. Generar música coherente y de calidad, manteniendo continuidad musical y evitando degradaciones perceptibles respecto al modelo base.
2. Mejorar el control modal para que las salidas reflejen progresiones y color armónico acordes al modo objetivo.
3. Diseñar y validar un protocolo de evaluación reproducible, combinando selección determinada de checkpoints y evaluación musical manual con rúbrica.

1.2. Motivación

La motivación principal surge de una limitación habitual en modelos musicales actuales: pueden generar piezas convincentes, pero el control armónico de alto nivel sigue siendo incompleto cuando se requiere precisión musical. En producción real, poder indicar no solo estilo o instrumentación, sino también modalidad, incrementa de forma directa el valor creativo y técnico del sistema.

Desde una perspectiva aplicada, el control modal es útil para composición asistida, prototipado de ideas armónicas y personalización de contenido musical para medios audiovisuales. Desde una perspectiva técnica, [LoRA](#) permite explorar estas mejoras con menor coste computacional y con adaptadores ligeros, facilitando iteración experimental frecuente y trazable.

1.3. Justificación

Este trabajo se justifica por la necesidad de cerrar la brecha entre calidad perceptiva y control musical estructurado en modelos generativos. A nivel académico, aporta una metodología reproducible para estudiar condicionamiento modal sobre modelos preentrenados. A nivel práctico, ofrece una estrategia incremental para añadir funcionalidad armónica sin comprometer de forma severa las capacidades musicales generales del modelo base.

La relevancia metodológica del proyecto reside en su enfoque dual de evaluación: una fase automática para reducir el espacio de búsqueda y una fase de escucha informada para validar musicalidad real. Esta combinación hace que los resultados sean más defendibles que una evaluación puramente automática o puramente subjetiva.

1.4. Preguntas de investigación y alcance

Para acotar el problema y evitar conclusiones ambiguas, el trabajo se estructura en torno a tres preguntas de investigación:

1. **RQ1.** *¿Es posible mejorar control modal sobre ACE-Step 1.5 mediante LoRA sin perder calidad musical global?*

2. **RQ2.** *¿Qué configuraciones de hiperparámetros y etiquetado ofrecen mejor equilibrio entre estabilidad armónica y separabilidad modal?*
3. **RQ3.** *¿Cómo evaluar de forma reproducible una propiedad musical compleja como la modalidad, combinando métricas automáticas y escucha informada?*

El alcance del proyecto es experimental y aplicado: se trabaja sobre un modelo preentrenado (ACE-Step 1.5), con adaptación eficiente por LoRA y dataset propio curado manualmente. No se aborda el reentrenamiento completo del modelo fundacional ni la detección automática de modo en audio arbitrario.

1.5. Contribuciones del trabajo

Las contribuciones principales de este [PFG](#) son las siguientes:

1. Diseño e implementación de un flujo experimental completo para control modal sobre ACE-Step, incluyendo preparación de datos, preprocesado, entrenamiento LoRA e inferencia por lotes.
2. Construcción de un dataset modal propio de 102 clips etiquetados en los siete modos diatónicos, con curado manual y trazabilidad de clases para análisis posterior.
3. Definición y ejecución completa de un protocolo de evaluación reproducible en dos fases: un ranking determinista de checkpoints y una evaluación perceptual sistemática con rúbrica de cuatro criterios, aplicada audio a audio sobre la totalidad de los candidatos de la búsqueda de hiperparámetros, con apoyo instrumental (guitarra) para verificar centro tonal y color modal. Esta evaluación manual constituye el principal mecanismo de validación del trabajo, dado que las métricas automáticas disponibles no capturan el carácter modal de forma fiable.
4. Identificación de una configuración LoRA de referencia con control modal parcial y buena calidad global, así como de sus limitaciones más relevantes en modos menores y locrio.
5. Propuesta de una estrategia de mejora incremental, conservadora con el modelo base, para reforzar separabilidad modal sin degradar musicalidad general.

Adicionalmente, el trabajo aporta una contribución de ingeniería experimental relevante: la detección y corrección de un error de parseo en la orquestación de inferencia por lotes, que afectaba

a la validez de la comparativa entre bloques de prompts. Esta corrección permitió recuperar trazabilidad y fiabilidad en la fase de análisis.

El código fuente, los scripts del pipeline experimental y los resultados de la evaluación manual están disponibles públicamente en:

<https://github.com/nachofrancoalm-dot/ACE-Step-1.5-LoRA-modal-music>

1.6. Estructura de la memoria

La memoria se organiza en los siguientes capítulos:

- **Estado de la cuestión** (Cap. 2): panorama de modelos de generación musical, funcionamiento de ACE-Step y LoRA, y fundamentos de los modos diatónicos necesarios para entender el problema.
- **Metodología** (Cap. 3): construcción del dataset, entrenamiento LoRA, búsqueda de hiperparámetros, pipeline de inferencia y protocolo de evaluación en dos fases.
- **Resultados y discusión** (Cap. 4): análisis de las configuraciones entrenadas, comparativa por modo, búsqueda de hiperparámetros y experimento de confirmación.
- **Conclusiones y trabajo futuro** (Cap. 5): respuesta a las preguntas de investigación y líneas abiertas.
- **Impacto social y medioambiental**: análisis de implicaciones del proyecto en el marco de los ODS.

2. Estado de la cuestión

2.1. Generación musical con modelos generativos

La generación automática de música ha evolucionado desde enfoques simbólicos a arquitecturas profundas capaces de sintetizar audio de alta calidad. Los modelos actuales pueden capturar textura, instrumentación y estructura temporal, pero suelen presentar limitaciones cuando se les exige control fino sobre variables armónicas globales.

En particular, el salto de calidad tímbrica conseguido por modelos recientes no implica control compositivo equivalente. Es frecuente obtener audio convincente en superficie (timbre, mezcla, continuidad local) pero con menor fiabilidad al imponer restricciones de alto nivel como centro tonal, función armónica o modalidad sostenida.

Este desacople entre calidad sonora y control estructural explica por qué la evaluación de sistemas musicales no puede limitarse a plausibilidad perceptiva general: es necesario verificar también obediencia a restricciones musicales explícitas.

2.2. ACE-Step como base de trabajo

[ACE-Step](#) es un sistema orientado a generación musical condicionada por texto, con capacidad para producir resultados de calidad en hardware de consumo. Para este proyecto, ACE-Step se emplea como modelo base sobre el que se aplican adaptadores [LoRA](#), evitando reentrenamientos completos y permitiendo iteraciones rápidas.

La elección de ACE-Step 1.5 responde a un criterio práctico y metodológico. En primer lugar, su código es completamente accesible, lo que permite intervenir directamente sobre el flujo de entrenamiento y aplicar adaptadores LoRA sobre módulos concretos del modelo (algo que las alternativas comerciales como Suno o Udio no permiten). Además, ofrece un pipeline reproducible, una inferencia estable y un coste computacional asumible para experimentación iterativa.

Esto permite centrar la investigación en el control modal, en lugar de dedicar el esfuerzo principal a resolver limitaciones de infraestructura.

2.3. Panorama actual de modelos de generación musical

El panorama actual combina servicios comerciales orientados a usuario final y modelos abiertos pensados para investigación o integración técnica. En el primer grupo destacan plataformas como Suno y Udio, que enfatizan la facilidad de uso, la calidad percibida y la generación a partir de descripciones textuales o creativas directas **suno2026home**, **udio2026home**. Estas soluciones han consolidado el interés por la generación musical automática, pero su foco principal no está en exponer mecanismos finos de control armónico ni en permitir experimentación reproducible a bajo nivel.

En el segundo grupo aparecen propuestas abiertas como MusicGen (parte del marco AudioCraft de Meta), Riffusion y ACE-Step **copet2023simple**, **riffusion2022**, **ace_step2025**. MusicGen demostró que es posible construir un sistema abierto de generación musical condicionado por texto con entrenamiento e inferencia accesibles **copet2023simple**. Riffusion, por su parte, adoptó un enfoque distinto: convertir el audio en *espectrograma* (una representación visual del sonido, donde el eje horizontal es el tiempo y el vertical la frecuencia) y aplicar un modelo de difusión de imágenes sobre esa representación, que después se vuelve a convertir a audio **riffusion2022**. En paralelo, MusicLM exploró la generación musical condicionada por texto a gran escala **agostinelli2023musiclm**, AudioLDM popularizó la difusión latente para audio condicionado por texto **liu2023audioldm** y Stable Audio Open publicó pesos abiertos de un modelo de generación musical de alta calidad **evans2024stableaudio**. ACE-Step se sitúa en esta línea como una de las propuestas abiertas más avanzadas, tanto por su arquitectura como por la disponibilidad de código, entrenamiento y adaptación mediante LoRA **ace_step2025**.

Esta comparativa es relevante para el presente trabajo porque muestra un hueco claro: los modelos comerciales priorizan experiencia de uso y resultados de gran calidad, mientras que los modelos abiertos avanzados facilitan control experimental, pero a menudo no ofrecen, de forma consistente, control modal fino y verificable. La aportación de este ámbito de trabajo se sitúa precisamente en ese punto: estudiar si un modelo abierto de alto nivel puede aprender un control modal consistente sin perder calidad global.

2.4. Funcionamiento conceptual de ACE-Step y del ajuste LoRA

De forma simplificada, ACE-Step combina cuatro bloques principales, que se ilustran en la Figura 2.1.

Bloque de condicionamiento textual. El encoder Qwen3-0.6B transforma instruction, caption y metadatos en embeddings semánticos. Este bloque está congelado durante todo el fine-tuning.

Encoders auxiliares. El Lyric Encoder procesa la letra estructurada de la canción. El Timbre Encoder, por su parte, recibe un audio de referencia opcional y extrae de él una huella tímbrica (color e instrumentación) que el modelo puede usar para condicionar la salida en ese mismo registro sonoro. Ambos son entrenables en fine-tuning completo del modelo base, pero permanecen congelados en este trabajo.

VAE 1D. Codifica el audio de entrada (48 kHz, estéreo) en una representación latente comprimida en el eje temporal: cada *patch* agrupa 2 muestras consecutivas, reduciendo a la mitad la longitud de la secuencia que el resto del modelo debe procesar. El VAE está congelado; sus pesos no se modifican en ningún escenario de entrenamiento.

DiT con SWA (N bloques). Es el núcleo generativo. Su arquitectura sigue el paradigma *Diffusion Transformer* [peebles2023dit](#), que combina los bloques de atención de Transformer [vaswani2017attention](#) con un objetivo de difusión/flujo. Cada bloque contiene self-attention, cross-attention y una red feed-forward (FFN). El condicionamiento textual entra mediante cross-attention (flecha desde Qwen3). Es en las capas de atención de este bloque donde se inyectan los adaptadores LoRA en este trabajo.

El ajuste mediante [LoRA](#) no modifica ninguno de los parámetros del modelo base; introduce matrices adicionales de bajo rango en las capas seleccionadas [hu2022lora](#). Esto permite especializar el modelo en una tarea concreta, en este caso el control modal, con un coste de entrenamiento y almacenamiento mucho menor que un fine-tuning completo.

La hipótesis de trabajo es que, manteniendo congelado el grueso del conocimiento musical del modelo base, los adaptadores LoRA pueden aprender una señal adicional asociada a modalidad. El equilibrio es delicado: una adaptación demasiado agresiva puede perjudicar musicalidad general, mientras que una adaptación demasiado suave puede no aportar separabilidad modal suficiente.

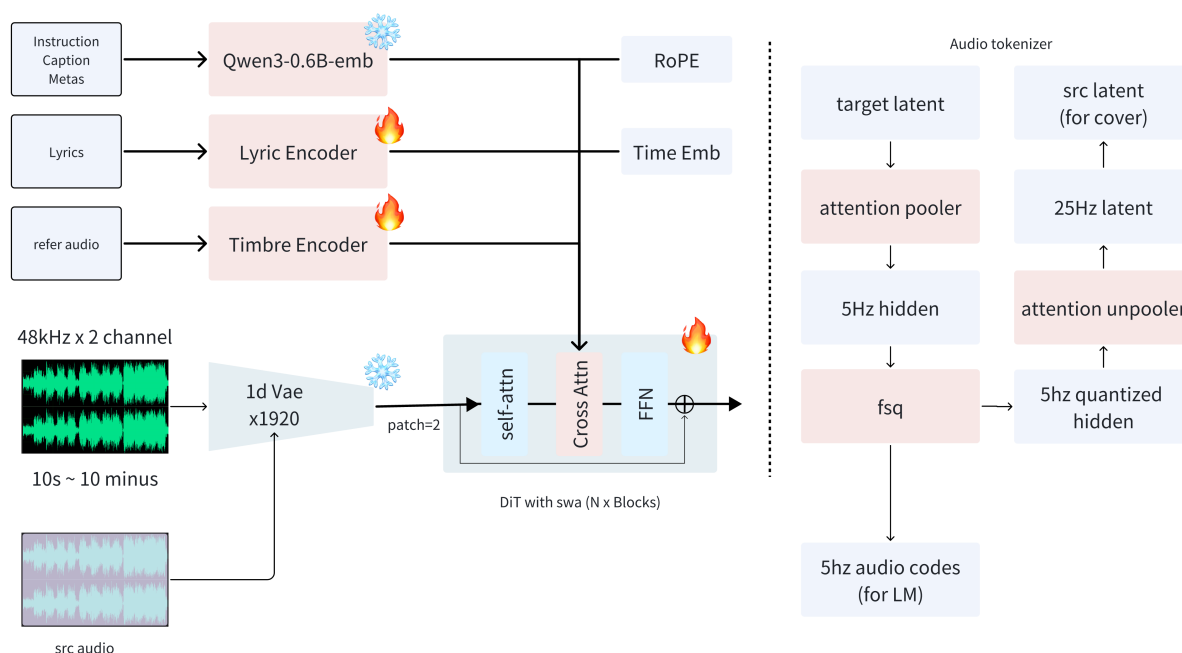


Figura 2.1. Arquitectura de ACE-Step 1.5. Los bloques marcados con *snowflake* (Qwen3, VAE) permanecen congelados en todos los escenarios. Los marcados con *llama* son entrenables en fine-tuning completo. Con LoRA, **todo** el modelo queda congelado y solo se añaden matrices de bajo rango en `q_proj`, `k_proj`, `v_proj` y `o_proj` de la Cross Attention del DiT.

Desde el punto de vista del estado del arte en *parameter-efficient fine-tuning* **ding2023peft**, esta hipótesis es coherente con el uso de LoRA en tareas donde se desea especializar comportamiento sin destruir capacidades generales del modelo base. En música, la dificultad adicional es que el objetivo no es solo semántico, sino perceptivo y estructural en el tiempo.

En consecuencia, el criterio de “éxito” no puede reducirse a una sola métrica de clasificación: debe incorporar estabilidad temporal, consistencia modal por modo y validación auditiva de la salida generada.

2.5. Los modos diatónicos

Para comprender el problema que aborda este trabajo, es necesario entender qué es un modo musical y por qué modos distintos producen sonoridades distintas, incluso cuando comparten exactamente las mismas notas.

2.5.1. La escala de C mayor como referencia

Una **escala musical** es una colección ordenada de notas separadas por distancias fijas. La distancia mínima entre dos notas consecutivas en el sistema occidental es el **semitono** (S); el doble de esa distancia es un **tono** (T).

A lo largo de esta memoria se utiliza la **nomenclatura anglosajona** para nombrar las notas, por coherencia con los *prompts*, el código del proyecto y la literatura de generación musical empleada. La equivalencia con la notación española es la siguiente:

Anglosajona	C	D	E	F	G	A	B
Española	Do	Re	Mi	Fa	Sol	La	Si

La escala de C mayor —la más familiar, equivalente a las teclas blancas del piano entre una C y la siguiente— sigue el patrón:

$$C \xrightarrow{T} D \xrightarrow{T} E \xrightarrow{S} F \xrightarrow{T} G \xrightarrow{T} A \xrightarrow{T} B \xrightarrow{S} C$$

La sucesión **T–T–S–T–T–T–S** es la firma de la escala mayor: un patrón fijo de cinco tonos y dos semitonos (uno entre el 3.º y el 4.º grado, otro entre el 7.º y la octava) que define el carácter *mayor*: brillante, estable y resolutivo.

La Figura 2.2 ilustra este patrón sobre un teclado de piano. Las teclas negras —que no forman parte de esta escala— corresponden a los semitonos intermedios entre las blancas donde no hay tono completo.




Figura 2.2. Escala de Do mayor sobre un teclado de piano. Las teclas azules son las siete notas de la escala; la tónica (Do) aparece en azul oscuro. Las marcas T (verde) y S (rojo) indican la distancia entre notas consecutivas de la escala.

2.5.2. De la escala a los modos: mismo material, distinto punto de partida

Los siete **modos diatónicos** se obtienen tomando las mismas siete notas de Do mayor, pero comenzando en cada una de ellas. Al cambiar el punto de partida, la tónica cambia, y con ella la distribución de tonos y semitonos respecto a esa nueva raíz. Esto altera qué intervalos caen sobre la nota de reposo y, por tanto, el carácter percibido de la música.

La Figura 2.3 muestra los siete modos junto a su patrón de intervalos y su nota característica —la nota que distingue perceptivamente ese modo del jónico o del eólico y que define su color armónico particular.

Los 7 modos diatónicos derivados de la escala de Do mayor
Mismas notas, distinto punto de partida → distinto patrón de intervalos

	Grado 1	Grado 2	Grado 3	Grado 4	Grado 5	Grado 6	Grado 7
Jónico <i>Mayor natural — estable, brillante</i>	C T	D T	E S	F T	G T	A T	B S
Dórico <i>Menor con 6ª mayor — melancolía jazz</i>	D T	E S	F T	G T	A T	B S	C T
Frigio <i>Menor con 2ª menor — flamenco, misterio</i>	E S	F T	G T	A T	B S	C T	D T
Lidio <i>Mayor con 4ª aumentada — etéreo, fantástico</i>	F T	G T	A T	B S	C T	D T	E S
Mixolidio <i>Mayor con 7ª menor — blues, rock</i>	G T	A T	B S	C T	D T	E S	F T
Eólico <i>Menor natural — oscuro, clásico</i>	A T	B S	C T	D T	E S	F T	G T
Locrio <i>Disminuido — muy inestable</i>	B S	C T	D T	E S	F T	G T	A T

Tónica del modo
 Nota característica
 Resto de notas
 S = semitono
 T = tono

Figura 2.3. Los siete modos diatónicos derivados de la escala de Do mayor. Cada fila comienza en una nota distinta; el patrón T/S resultante cambia en cada modo. La celda naranja señala la nota característica de cada modo, es decir, la nota que lo diferencia armónicamente del mayor o del menor natural.

Los modos se dividen habitualmente en dos grandes grupos según su carácter:

- **Modos mayores** (tienen 3ª mayor sobre la tónica): jónico, lidio y mixolidio. Suenan brillantes y estables.
- **Modos menores** (tienen 3ª menor sobre la tónica): dórico, frigio, eólico y locrio. Suenan más oscuros o tensos.

La Tabla 2.1 sintetiza el carácter de cada modo, su nota característica respecto al jónico, los

géneros musicales donde aparece con mayor frecuencia y ejemplos de canciones populares que lo ilustran con claridad.

Tabla 2.1. Caracterización de los siete modos diatónicos con ejemplos de música popular

Modo	Carácter	Género típico	Ejemplos
Jónico	Brillante, estable	Pop, clásico, folk	<i>Imagine</i> (Lennon, 1971); <i>Let It Be</i> (The Beatles, 1970)
Dórico	Melancólico, con luminosidad	Jazz modal, soul, rock	<i>So What</i> (Miles Davis, 1959); <i>Oye Como Va</i> (Santana, 1970)
Frigio	Oscuro, tenso, exótico	Flamenco, metal, música árabe	Bulerías y soleá flamencas; <i>Wherever I May Roam</i> (Metallica, 1991)
Lidio	Etéreo, flotante, onírico	Música de cine, jazz	Tema de apertura de <i>Los Simpsons</i> (Elfman, 1989); <i>Flying</i> (The Beatles, 1967)
Mixolidio	Mayor con tensión, bluesy	Blues, rock, celta	<i>Norwegian Wood</i> (The Beatles, 1965); <i>Gloria</i> (Van Morrison, 1964)
Eólico	Oscuro, introspectivo	Rock, pop, clásico	<i>All Along the Watchtower</i> (Dylan, 1967); <i>Losing My Religion</i> (R.E.M., 1991)
Locrio	Inestable, disonante	Metal progresivo, jazz avanzado	Muy raro en música popular; aparece en algunos pasajes de metal y jazz moderno

La escasez de ejemplos populares de locrio ilustra de forma directa por qué ese modo es el más difícil de controlar: su tritono sobre la tónica genera una inestabilidad tan acusada que la música tiende a resolver hacia otro centro tonal. Esta misma dificultad se refleja en los resultados experimentales de este trabajo, donde locrio es el modo con peor puntuación en evaluación manual (Sección 4.7).

2.5.3. Por qué una sola nota cambia el carácter: el ejemplo dórico

El caso más ilustrativo de cómo una diferencia mínima produce un efecto radical es la comparación entre el modo eólico (menor natural) y el modo dórico. Ambos son modos menores que comparten seis de sus siete notas; la única diferencia es la sexta escalar:

- **Re eólico:** D – E – F – G – A – **Bb** – C (6ª menor = Si bemol)
- **Re dórico:** D – E – F – G – A – **B** – C (6ª mayor = Si)

Esa única nota —Si bemol frente a Si natural— es suficiente para transformar una sonoridad oscura y clásica (eólico) en una sonoridad melancólica con un punto de luminosidad (dórico), característica del jazz modal y del soul. Canciones como *So What* de Miles Davis o *Scarborough Fair* son ejemplos conocidos del modo dórico.

La Figura 2.4 ilustra cómo, partiendo de las mismas notas de Do mayor, el modo jónico (raíz en Do) y el modo dórico (raíz en Re) generan patrones de intervalos completamente distintos sobre sus respectivas tónicas.




Figura 2.4. Comparativa entre Do jónico y Re dórico. Ambos modos utilizan exactamente las mismas siete notas (las teclas blancas del piano), pero al tomar Raíz distinta, el patrón de intervalos cambia: el semitono cae en distinto lugar sobre la tónica, lo que determina el carácter del modo. La nota característica del dórico (Si, naranja) es la que lo distingue del menor natural.

2.5.4. Implicaciones para la generación automática de música

Este análisis tiene una consecuencia directa para el problema que aborda el presente trabajo. Un modelo generativo que aprende a producir música a partir de grandes volúmenes de datos tiende a reflejar los sesgos de esa distribución. Dado que la música popular está dominada por modos mayores y por el menor natural (eólico), el modelo base tendrá un sesgo hacia esas sonoridades.

Cuando se le pide que genere en modo dórico, el modelo puede producir una pieza en Re menor ignorando la sexta mayor —una diferencia de un solo semitono que pasa desapercibida si no se escucha con atención, pero que elimina el carácter específicamente dórico. Este es precisamente el tipo de error sistemático que se observa en la evaluación manual del presente trabajo (Sección 4.9), y la razón por la que el control modal es un reto más sutil de lo que aparenta.

2.6. Control modal y dificultad del problema

Imponer modalidad de forma robusta implica controlar el centro tonal, el color modal y la estabilidad armónica en el tiempo. En la práctica, esto es más exigente que generar audio plausible, porque requiere mantener coherencia musical global y diferenciación entre modos cercanos, especialmente en contextos con progresiones ambiguas.

Además, la modalidad es una propiedad difícil de medir de forma automática: un oyente puede percibir claramente el carácter modal de una pieza aunque la tónica no se afirme con fuerza en cada instante. Por eso una evaluación fiable necesita combinar métricas automáticas, que dan una señal cuantitativa pero parcial, con escucha humana estructurada que confirme el color modal real.

2.7. Síntesis del estado de la cuestión y hueco identificado

Del análisis anterior se desprende un hueco claro: existen modelos capaces de generar música de calidad, y existen técnicas eficientes de adaptación como LoRA, pero faltan protocolos prácticos

y reproducibles para validar control modal fino en escenarios de coste moderado. Este trabajo se posiciona en ese hueco, proponiendo una metodología experimental replicable que combina evaluación automática, evaluación musical informada y trazabilidad de decisiones experimentales.

Adicionalmente, el desarrollo del proyecto ha requerido intervenir directamente sobre los ficheros de entrenamiento de ACE-Step para corregir incidencias detectadas durante la experimentación (problemas de carga de adaptadores, comportamiento inconsistente en `save_every_n_epochs`, errores de orquestación en inferencia por lotes). Estas correcciones fueron necesarias para garantizar la validez de los experimentos posteriores y se documentan en el capítulo de metodología.

2.8. Posicionamiento del trabajo respecto al estado actual

La Tabla 2.2 resume el posicionamiento de este PFG frente a enfoques habituales en generación musical condicionada.

Tabla 2.2. Posicionamiento del trabajo respecto a enfoques habituales

Dimensión	Enfoque habitual	Enfoque en este trabajo
Adaptación del modelo	Fine-tuning amplio o no controlado	LoRA focalizado y conservador
Objetivo principal	Calidad perceptiva general	Calidad + control modal explícito
Evaluación	Predominio de métrica automática	Pipeline dual: automática + escucha informada
Selección experimental	Iteración poco trazable	Ranking determinista de checkpoints
Coste computacional	Alto o variable	Acotado y compatible con iteración académica

En síntesis, el estado de la cuestión justifica una estrategia experimental centrada en trazabilidad, control de sesgos y validación dual. Este enfoque marca la transición natural hacia la metodología empleada en el proyecto.

3.1. Entorno y recursos

El trabajo se distribuyó entre dos entornos: el ordenador personal del autor y una máquina remota con GPU proporcionada por el tutor a través de la universidad. Esta separación no fue una elección metodológica sino una necesidad: el equipo local no dispone de GPU suficiente para entrenar modelos generativos de este tamaño, por lo que la totalidad del entrenamiento y la inferencia se ejecutó en remoto.

Máquina local. Ordenador personal utilizado para el desarrollo de scripts, edición de la memoria, análisis de resultados, escucha de audios generados y visualización de figuras.

Máquina remota (GPU). Servidor Linux con GPU NVIDIA, accesible a través de la red universitaria, sobre el que se ejecutaron los entrenamientos LoRA y la inferencia por lotes. Se emplearon las siguientes herramientas de acceso remoto, cuyo uso no había formado parte del plan de estudios previo y fue necesario aprender durante el proyecto:

- **PuTTY.** Cliente SSH para Windows que permite abrir terminales en la máquina remota. Se utilizó para lanzar entrenamientos, ejecutar scripts de inferencia y monitorizar el progreso de los experimentos en tiempo real.
- **WinSCP.** Programa para transferir ficheros entre el equipo local y el servidor a través de SFTP (un protocolo de transferencia de ficheros sobre SSH). Se empleó para enviar scripts, datasets preprocesados y configuraciones al servidor, y para descargar los resultados (CSV de métricas, audios generados, figuras) al equipo local para su análisis.
- **Túnel SSH.** Mediante reenvío de puertos (*port forwarding*) por SSH, se expusieron localmente la interfaz Gradio y la API REST del servidor. Esto permitió interactuar con el modelo desde el navegador del equipo local sin necesidad de abrir puertos en el cortafuegos universitario.

Este flujo de trabajo—desarrollo local, ejecución remota, descarga de resultados—es el habitual en investigación con modelos de aprendizaje profundo y requirió familiarizarse con herramien-

tas y conceptos de administración de sistemas que complementaron la formación académica recibida.

El flujo experimental completo incluyó: preparación de datos, preprocesado a tensores, entrenamiento LoRA, inferencia por lotes y evaluación manual asistida por scripts.

3.2. Construcción del dataset

Se construyó un dataset de 102 clips de audio de entre 20 y 50 segundos. Los fragmentos se obtuvieron a partir de canciones existentes y fueron recortados manualmente para conservar secciones representativas a nivel armónico. La selección de canciones y la comprensión del carácter perceptivo de cada modo se apoyaron, entre otros recursos, en el canal de divulgación musical *David Bennett Piano*¹, cuyo enfoque didáctico sobre los modos en música popular resultó especialmente útil para identificar ejemplos con carácter modal claro y verificable.

Distribución por modo:

Tabla 3.1. Distribución de clips por modo en el dataset

Modo	Número de clips
Jónico	7
Dórico	21
Frigio	16
Lidio	18
Mixolidio	18
Eólico	14
Locrio	8

El reparto por modo no es uniforme y responde a dos decisiones deliberadas. En primer lugar, el modo jónico aparece deliberadamente infrarrepresentado: la música occidental —y por extensión, la mayor parte del corpus de entrenamiento original del modelo base— es predominantemente jónica, por lo que se entendió que era preferible reservar la capacidad de adaptación del LoRA para los modos minoritarios. Los resultados confirman esta intuición: el modo jónico obtiene de las mejores puntuaciones en evaluación manual a pesar de contar con solo 7 clips,

¹Canal de YouTube *David Bennett Piano*: <https://www.youtube.com/@davidbennettpiano> (consultado en 2025–2026). El canal ofrece análisis audio-musicales accesibles sobre modos diatónicos y su uso en música popular, lo que facilitó la identificación de ejemplos representativos para cada modo.

lo que sugiere que un número pequeño de ejemplos bien seleccionados es suficiente cuando el modelo base ya conoce bien la sonoridad. En el extremo contrario, el modo locrio fue el más difícil de representar: encontrar ejemplos claros y musicalmente significativos en música popular resultó muy complicado debido a su rareza estilística, lo que constituye una limitación conocida para el entrenamiento de ese modo.

3.3. Entrenamiento LoRA

La línea experimental principal utiliza ACE-Step 1.5 y adaptadores LoRA con configuraciones exploradas por rejilla de hiperparámetros. La configuración más prometedora de la fase exploratoria inicial fue:

- rank = 64
- alpha = 128
- dropout = 0.05
- learning rate = $5 \cdot 10^{-5}$
- checkpoint de referencia: epoch 100

Con el fin de no degradar capacidades generales del modelo base, se utilizó una estrategia de etiquetado conservadora en los captions de entrenamiento, centrada en el modo objetivo y evitando fijar estilo, tempo o instrumentación de forma rígida.

La configuración de referencia del estudio (run_D) se ejecutó con los parámetros detallados en la Tabla 3.3 y ha sido completamente evaluada tanto de forma automática como mediante escucha informada.

3.3.1. Interfaz de entrenamiento y parámetros configurables

ACE-Step 1.5 incorpora una interfaz gráfica Gradio con una pestaña de entrenamiento LoRA que permite configurar todos los parámetros sin necesidad de editar código. La Figura 3.1 muestra esta interfaz tal y como se utilizó durante el proyecto.

LoRA Training for ACE-Step
Build datasets from your audio files and train custom LoRA adapters

Dataset Builder Train LoRA Train LoKr

training.train_section_tensors
Select the directory containing preprocessed tensor files (.pt files). These are created using the 'Preprocess' button in the 'Dataset Builder' tab.

Preprocessed Tensors Directory
./preprocessed_tensors/modal_v2

Load Dataset

Dataset info.
Found 102 tensor files in /home/musica/ACE-Step-1.5/preprocessed_tensors/modal_v2
No manifest.json found - using all .pt files

training.train_section_lora

LoRA Rank (r)
4 32 256

LoRA Alpha
4 32 512

LoRA Dropout
0 0.05 0.5

training.train_section_params

Learning Rate
0.0001

Max Epochs
100 160 4000

Batch Size
1 8 16

Gradient Accumulation
1 4 16

Save Every N Epochs
1 20 1000

Shift
1 3 5

Seed
42

Output Directory
./lora_output/confirm_r32_a32_lre-4

Resume Checkpoint
./lora_output/checkpoints/epoch_200

Figura 3.1. Interfaz de entrenamiento LoRA de ACE-Step 1.5. Los paneles permiten seleccionar el dataset de tensores, configurar los hiperparámetros LoRA y los parámetros generales del entrenamiento, y especificar el directorio de salida de checkpoints.

La interfaz organiza los parámetros en tres grupos. La Tabla 3.2 describe cada uno, su significado y su efecto sobre el entrenamiento.

Tabla 3.2. Parámetros configurables en la interfaz de entrenamiento LoRA

Parámetro	Significado	Efecto en el entrenamiento
<i>Parámetros LoRA</i>		
Rank (r)	Dimensión de las matrices de bajo rango A y B	Mayor rango = más parámetros entrenables = más capacidad de adaptación, pero mayor coste de memoria y riesgo de sobreentrenamiento
Alpha (α)	Factor de escala del adaptador (ver Ec. 3.1)	Controla la magnitud de la actualización LoRA; cuando $\alpha = r$ la escala es neutra (1.0)
Dropout	Probabilidad de desactivar activaciones LoRA durante entrenamiento	Regularización: valores altos reducen sobreajuste pero enlentecen la convergencia
<i>Parámetros de entrenamiento</i>		
Learning rate	Tamaño del paso en el descenso de gradiente	Valor crítico: demasiado alto produce inestabilidad, demasiado bajo convergencia lenta
Max epochs	Número máximo de épocas completas sobre el dataset	Determina la duración máxima; el checkpoint óptimo suele estar antes del final
Batch size	Muestras procesadas por paso de gradiente	Limitado por VRAM; valores bajos aumentan el ruido del gradiente pero permiten mayor variabilidad
Gradient accumulation	Número de pasos acumulados antes de actualizar pesos	El batch efectivo real es $\text{batch_size} \times \text{acumulación}$; permite simular batches mayores sin coste de memoria adicional
Save every N epochs	Frecuencia de guardado de checkpoints intermedios	Frecuencia alta permite analizar la curva de convergencia y seleccionar el checkpoint óptimo
Shift	Parámetro de la distribución lognormal de muestreo de timesteps	Valores altos priorizan timesteps con mayor ruido (etapas iniciales del flujo), modificando qué aspectos del audio aprende a reconstruir el modelo
Seed	Semilla aleatoria	Garantiza reproducibilidad del entrenamiento

En este estudio, el batch efectivo fue siempre $1 \times 4 = 4$ muestras (batch size = 1 con acumulación de gradiente = 4), y se guardó un checkpoint cada 20 épocas para permitir la selección del mejor punto de convergencia mediante evaluación auditiva posterior.

3.3.2. Qué se congela con LoRA y función de pérdida

En un fine-tuning LoRA, **todos los parámetros del modelo base quedan congelados**. En lugar de modificar directamente los pesos W de las capas objetivo, se añade una rama paralela de bajo rango:

$$W' = W + \frac{\alpha}{r} BA \quad (3.1)$$

donde $W \in \mathbb{R}^{d \times k}$ son los pesos originales congelados (con d la dimensión de salida y k la dimensión de entrada de la capa lineal proyectada), $B \in \mathbb{R}^{d \times r}$ y $A \in \mathbb{R}^{r \times k}$ son las matrices LoRA entrenables, r es el rango y α el factor de escala. Solo A y B reciben gradiente; el resto del modelo no.

En este trabajo, los módulos objetivo son q_proj, k_proj, v_proj y o_proj de los bloques Cross Attention del DiT, es decir, las proyecciones de query, key, value y output de la atención que conecta el texto condicionante con el latente de audio. El número de parámetros entrenables es del orden de $2 \times r \times (d + k) \times N_{\text{bloques}}$, representando menos del 1 % del total del modelo.

ACE-Step utiliza *flow matching* [lipman2023flow](#) como objetivo de entrenamiento, un marco emparentado con los modelos de difusión clásicos [ho2020ddpm](#). La idea, en términos sencillos, es la siguiente: durante el entrenamiento se parte del latente limpio z_1 (la representación del audio real) y se mezcla con ruido z_0 en una proporción intermedia t , obteniendo un latente parcialmente ruidoso z_t . Al modelo se le pide que, observando z_t , prediga la *dirección de limpieza*: el vector $(z_1 - z_0)$ que llevaría del ruido al audio. La pérdida mide cuánto se parece la predicción del modelo a esa dirección real, mediante el error cuadrático medio entre ambos vectores:

$$\mathcal{L} = \mathbb{E}_{t, z_0, z_1} [\|v_\theta(z_t, t, c) - (z_1 - z_0)\|^2] \quad (3.2)$$

donde v_θ es la predicción del modelo y c es el embedding del texto condicionante. El valor t se muestrea de una distribución lognormal con $\mu = -0,4$ y $\sigma = 1,0$, lo que concentra el entrenamiento en niveles de ruido intermedios, donde la señal de aprendizaje es más informativa que en los extremos (ni ruido puro ni audio ya limpio).

3.3.3. Flujo de entrenamiento con ejemplo

Para una muestra de entrenamiento con prompt “*dorian mode, jazz-fusion instrumental, D dorian...*” y su clip de audio correspondiente, el flujo es:

1. El audio (48 kHz) pasa por el VAE congelado y se obtiene el latente limpio z_1 .
2. Se muestrea t y ruido z_0 ; se calcula el latente ruidoso $z_t = (1 - t)z_0 + t z_1$.
3. El prompt pasa por el encoder Qwen3 congelado y genera el embedding c .
4. El DiT (con adaptadores LoRA activos) predice $v_\theta(z_t, t, c)$.
5. Se calcula la pérdida según la Ecuación 3.2.
6. El gradiente actualiza **únicamente** las matrices LoRA A y B de cada capa objetivo.

3.3.4. Trayectoria experimental y selección de hiperparámetros

El trabajo experimental siguió una progresión en tres fases sucesivas, cada una informada por los resultados de la anterior.

Fase exploratoria inicial. Se realizaron entrenamientos largos (del orden de 5 000 épocas) con guardado de checkpoint cada 200 épocas. La escucha de los audios reveló que a partir de la época 400 el modelo se encontraba claramente sobreentrenado: el audio dejaba de ser musicalmente legible. Esta fase, aunque no produjo configuraciones definitivas, fue clave para acotar el rango útil de épocas y descartar el uso exclusivo de la loss como criterio de parada.

Fase de afinado y configuración de referencia. Con el rango de épocas reducido a ~ 200 y guardado de checkpoint cada 20 épocas, se itera sobre rank, alpha y learning rate. Antes de llegar a la configuración adoptada como referencia se entrenaron varias variantes intermedias que sirvieron para acotar los rangos útiles de r y α y descartar combinaciones inestables; ninguna de ellas se toma como referencia del estudio pero todas contribuyeron a fijar la configuración final. El nombre run_D corresponde precisamente a la cuarta iteración de esta secuencia, que es la primera con resultados auditivos y automáticos suficientemente estables como para servir de línea base. La configuración resultante ($r = 64$, $\alpha = 128$, $lr = 5 \cdot 10^{-5}$) se adopta como referencia del estudio. La elección del learning rate $5 \cdot 10^{-5}$ se apoyó en evidencia empírica

directa: exploraciones previas con valores mayores produjeron resultados notablemente peores, mientras que $5 \cdot 10^{-5}$ permitía entrenamientos estables con buena convergencia auditiva.

Búsqueda sistemática y experimento de confirmación. A partir de run_D se diseña la búsqueda en rejilla de 24 configuraciones (Sección 3.4). La configuración más prometedora derivada del análisis posterior se valida mediante un experimento de confirmación dirigido (Sección 4.5).

Tabla 3.3. Configuración completa del entrenamiento run_D

Parámetro	Valor
Variante del modelo	turbo
Checkpoint base	./checkpoints
Dataset (tensores)	./preprocessed_tensors/modal_v2
Dispositivo	cuda:0
Precisión	bf16
LoRA rank (r)	64
LoRA alpha	128
LoRA dropout	0.05
Módulos objetivo	q_proj, k_proj, v_proj, o_proj
Bias	none
Learning rate	$5 \cdot 10^{-5}$
Batch size	1
Gradient accumulation	4
Batch efectivo	4
Epochs máximos	160
Warmup steps	100
Weight decay	0.01
Max grad norm	1.0
Seed	42
CFG dropout ratio	0.15
Timestep mu	-0,4
Timestep sigma	1.0
Data proportion	0.5
Output dir	./lora_output/modal_run_D
Guardado cada N epochs	20

3.4. Búsqueda sistemática de hiperparámetros

Con el fin de reducir la dependencia de decisiones manuales en la elección de hiperparámetros, se diseñó una búsqueda en rejilla sobre cuatro dimensiones: rango LoRA (*rank*), escala LoRA (*alpha*), tasa de aprendizaje y dropout. La Tabla 3.4 especifica los valores explorados.

Tabla 3.4. Rejilla de hiperparámetros de la búsqueda sistemática (24 configuraciones)

Hiperparámetro	Valores explorados
Rank (r)	32, 64, 128
Alpha (α)	32, 128
Learning rate	10^{-4} , 10^{-3}
Dropout	0.05, 0.10

El cruce completo genera 24 configuraciones, todas evaluadas con el mismo protocolo de inferencia por lotes: 7 modos $\times$ 2 semillas fijas (1111 y 2222) $\times$ checkpoint final (epoch 140). Esto garantiza comparabilidad directa entre experimentos. La métrica principal es `auto_score_0_1`, un índice normalizado que combina exactitud modal, estabilidad tonal y similitud con la plantilla modal teórica del modo objetivo.

El rango de tasas de aprendizaje explorado (10^{-4} y 10^{-3}) se eligió como exploración independiente en el orden de magnitud habitual de fine-tuning LoRA reportado en la literatura [hu2022lora](#), [ding2023peft](#). El valor $lr = 5 \cdot 10^{-5}$ utilizado en `run_D` ya había sido caracterizado de forma aislada en la fase previa y se reservó como referencia de comparación externa al grid, evitando duplicar puntos ya conocidos dentro del presupuesto computacional disponible.

3.5. Pruebas exploratorias no válidas y decisiones de descarte

Una parte relevante del trabajo consistió en iteraciones que no dieron resultados satisfactorios, pero que fueron clave para ajustar el enfoque metodológico.

En una fase inicial sobre ACE-Step 1.3 se obtuvieron resultados inestables, con variabilidad alta

entre checkpoints y menor robustez en inferencia. Esas pruebas se consideran exploratorias y no se toman como referencia principal en la comparativa final, ya que el entorno de entrenamiento y despliegue cambió posteriormente a ACE-Step 1.5.

Ya en ACE-Step 1.5, varias configuraciones de hiperparámetros fueron descartadas por evidencia empírica: degradación de calidad en checkpoints avanzados, sobreentrenamiento o escasa mejora modal frente al coste de evaluación. Este descarte no se realizó por impresión subjetiva aislada, sino por combinación de ranking determinista y escucha crítica estructurada.

3.6. Pipeline de inferencia y selección de checkpoints

Para reducir carga de evaluación manual, se empleó un pipeline determinista de ranking de checkpoints apoyado en scripts de inferencia por lotes. Los checkpoints mejor posicionados se sometieron después a escucha crítica y evaluación musical detallada.

En la iteración más reciente se añadió comparativa explícita entre variantes de prompt para aislar el efecto del condicionamiento textual:

- **Bloque B (detailed):** descripción modal detallada con más contexto musical.
- **Bloque E (mode-only):** prompt mínimo centrado en el nombre del modo.

Durante esta fase se detectó y corrigió un fallo en la forma en que el script de inferencia por lotes lee y separa los bloques de prompts del fichero de configuración: por un error en la lógica de detección de inicio de bloque, el contenido de un bloque podía “derramarse” parcialmente sobre el siguiente, de modo que ambas variantes recibían un prompt híbrido y la comparativa entre ellas resultaba artificialmente similar. La corrección detallada se documenta en la Sección 3.7.

Adicionalmente, en la fase de validación de checkpoints se identificó una incidencia de infraestructura en la carga de adaptadores LoRA durante inferencia por lotes. En determinadas condiciones, rutas temporales y nombres lógicos de adaptador podían provocar reutilización no deseada entre experimentos consecutivos. La incidencia se corrigió aislando de forma unívoca cada checkpoint (ruta temporal con identificador derivado de ruta completa) y verificando el resultado mediante comparación de huellas SHA-256 tanto en checkpoints como en audios generados. Esta verificación se incorporó como control de calidad previo al ranking final.

3.7. Implementación técnica del pipeline experimental

El flujo experimental completo se implementó como un conjunto de scripts Python independientes y encadenables, diseñados para ejecutarse en el servidor remoto mediante SSH. La Tabla 3.5 describe cada módulo, su entrada y salida, y su papel en el flujo general.

Tabla 3.5. Scripts del pipeline experimental y su función

Script	Función	Entrada / Salida
<code>prepare_modes_dataset.py</code>	Construcción y etiquetado del dataset modal	Clips de audio → estructura de carpetas por modo
<code>modal_hparam_sweep.py</code>	Orquestación de la búsqueda de hiperparámetros	Grid de configuraciones → 24 entrenamientos secuenciales
<code>modal_batch_infer.py</code>	Inferencia por lotes sobre checkpoints	Lista de checkpoints + prompts → audios generados
<code>modal_eval_pipeline.py</code>	Cálculo de métricas automáticas	Audios + modo esperado → CSV con <code>auto_score_0_1</code>
<code>modal_hparam_analysis.py</code>	Análisis y visualización de resultados	CSV de resultados → figuras y tablas de sensibilidad
<code>rank_checkpoints_per_experiment.py</code>	Ranking determinista de checkpoints	CSV de métricas → lista ordenada de candidatos
<code>prepare_manual_eval_shortlist.py</code>	Selección de candidatos para escucha informada	Ranking → subconjunto de checkpoints para evaluación manual
<code>regenerate_top_audios.py</code>	Regeneración de audios de los mejores checkpoints	Lista de candidatos → audios con semilla fija para evaluación

3.7.1. Incidencias técnicas detectadas y corregidas

Durante el desarrollo del pipeline se identificaron y corrigieron dos incidencias de carácter técnico que de no haberse detectado habrían comprometido la validez interna de los resultados.

Fallo de parseo de bloques en inferencia por lotes. El script `modal_batch_infer.py` organiza los prompts en bloques con nombre (p. ej. *Bloque B* para prompts detallados, *Bloque E* para prompts mínimos). En una versión temprana, un error en la lógica de detección del inicio de bloque podía hacer que el parser asignara contenido de un bloque al siguiente, mezclando las variantes de prompt entre sí. El resultado era que la comparativa entre tipos de prompt producía diferencias nulas o artificialmente pequeñas, ya que ambos bloques recibían en parte el mismo texto. La corrección consistió en añadir una verificación explícita de inicio y fin de bloque con marcadores sin ambigüedad, y ejecutar pruebas de humo (*smoke tests*) con salida controlada para confirmar que cada bloque recibía exactamente su contenido asignado.

Reutilización no deseada de adaptadores LoRA entre experimentos. Durante la validación en inferencia por lotes se detectó que, bajo ciertas condiciones de ruta temporal, el sistema podía cargar el adaptador del experimento anterior en lugar del correspondiente al checkpoint en curso. Esto ocurría porque ACE-Step gestiona los adaptadores mediante un nombre lógico que puede persistir en memoria entre llamadas consecutivas si la ruta física del adaptador no cambia. La corrección consistió en generar un identificador único para cada checkpoint derivado de su ruta completa, forzar la descarga del adaptador previo antes de cada carga, y verificar la integridad del experimento comparando la huella SHA-256 del archivo de pesos cargado con la del archivo esperado. Esta verificación se incorporó como paso obligatorio previo al cálculo de métricas.

Ambas correcciones se realizaron antes del análisis de resultados de la búsqueda sistemática y del experimento de confirmación, por lo que los datos presentados en el capítulo de resultados son válidos y están libres de estos sesgos.

3.8. Métricas automáticas y criterios de decisión

La fase automática se apoyó en el índice compuesto `auto_score_0_1`, calculado a partir de cinco métricas extraídas del *cromagrama* del audio generado. El cromagrama es una representación derivada del espectro: divide cada instante del audio en las 12 clases de altura del sistema tonal occidental (C, C#, D, ..., B) y mide cuánta energía sonora hay en cada una. El audio se procesa por ventanas temporales cortas, de modo que se obtiene un *vector de chroma* (12 valores, uno por nota) para cada ventana. La Figura 3.2 muestra un ejemplo de vector de chroma simulado para Re dórico, donde las notas diatónicas concentran la mayor parte de la energía y la tónica destaca sobre el resto. Sobre esta representación se calculan las siguientes métricas:




Figura 3.2. Ejemplo de vector de chroma para Re dórico (valores simulados). Cada barra representa la energía relativa de una clase de altura; la tónica (D, rojo) domina, las demás notas diatónicas (azul) concentran la mayor parte de la energía restante, y las notas no diatónicas (gris) presentan valores muy bajos. La línea de puntos indica la plantilla binaria diatónica utilizada en la métrica s_m . La 6ª mayor (Si) es la nota característica que distingue al dórico del eólico.

1. **In-mode ratio** (r_{im}). Proporción de energía espectral media concentrada en las alturas diatónicas del modo objetivo. Por ejemplo, para D dórico las notas válidas son D, E, F, G, A, B, C. Un valor de 0.85 indica que el 85 % de la energía cae en esas clases de altura.
2. **Frame-in-mode ratio** (r_{fm}). Variante por ventana temporal: proporción media (a lo largo de los frames) de energía dentro del modo. Penaliza configuraciones donde el promedio global parece correcto pero ventanas concretas se salen del modo.
3. **Estabilidad tonal** (s_t). Estabilidad de la clase de altura dominante entre ventanas consecutivas: 1 menos la proporción de transiciones de tónica dominante. Valores altos indican un centro tonal sostenido en el tiempo.
4. **Dominancia de tónica** (d_t). Proporción de ventanas cuya clase de altura dominante coincide con la tónica esperada del modo (p. ej. D en D dórico).
5. **Similitud con plantilla modal** (s_m). Similitud coseno entre el vector de chroma medio del audio y la plantilla binaria del modo objetivo (1 en las posiciones diatónicas, 0 en el resto), inspirada en los perfiles tonales de Krumhansl–Kessler **krumhansl1982**, que son distribuciones de prominencia perceptiva de las 12 clases de altura para cada tonalidad mayor y menor, obtenidas experimentalmente mediante valoraciones de oyentes.

Las cinco componentes se combinan en una media ponderada acotada al intervalo $[0, 1]$:

$$\text{auto_score_0_1} = 0,40 r_{\text{im}} + 0,20 r_{\text{fm}} + 0,20 s_t + 0,10 d_t + 0,10 s_m \quad (3.3)$$

Los pesos priorizan la *presencia diatónica* —es decir, cuánta energía del audio cae en las notas del modo objetivo— medida tanto de forma global (40 %) como ventana a ventana (20 %), y la estabilidad tonal (20 %), dejando la dominancia de tónica y la similitud con plantilla con un peso secundario (10 % cada una). De forma complementaria, el pipeline reporta una **exactitud modal** (`modal_accuracy`) basada en la estimación del modo más probable mediante el algoritmo de Krumhansl–Kessler **krumhansl1982**; esta métrica no entra en la Ecuación 3.3 y se utiliza como indicador binario adicional para diagnóstico.

La principal limitación de `auto_score_0_1` es su insensibilidad al color modal fino: un audio estable en C mayor puede obtener score alto para cualquier modo con tónica C, aunque no presente las notas características del modo (p. ej. la 6ª mayor del dórico o la 2ª disminuida del frigio). Por ello, los resultados automáticos se usan exclusivamente como filtro de candidatos y no como criterio definitivo de calidad musical.

Estas métricas se usaron para filtrar checkpoints y configuraciones candidatas, no como sustituto de la evaluación musical informada.

3.9. Evaluación manual

Esta evaluación constituye el principal mecanismo de validación del estudio. Se llevó a cabo audio a audio sobre el conjunto completo de candidatos seleccionados por el ranking automático, verificando con una guitarra el centro tonal y el color modal percibidos en cada muestra. Para cada audio evaluado se registró, además de la puntuación por rúbrica, una anotación breve con la justificación cualitativa de la nota asignada (presencia o ausencia de notas características, observaciones sobre modulación, comentarios sobre coherencia musical). Estas anotaciones permiten trazar el razonamiento detrás de cada puntuación y resultan especialmente útiles para el análisis por modo del Capítulo de resultados.

Una vez seleccionados los candidatos mediante el ranking automático, se realizó una evaluación de escucha informada con una rúbrica estructurada. El objetivo era capturar dimensiones de calidad musical que las métricas espectrales no pueden medir: en particular, si la música generada transmite el carácter modal objetivo de forma perceptualmente convincente.

La identificación de género y modo en audio es una tarea con larga trayectoria en recuperación de información musical **tzanetakis2002musical**, lo que justifica el uso de métricas espectrales

como cribado previo, reservando la escucha informada para la validación final.

La rúbrica consta de cuatro criterios, cada uno puntuado en una escala de 1 a 5 puntos, lo que da una puntuación máxima de 20 puntos por muestra:

Tabla 3.6. Rúbrica de evaluación manual (escala 1–5 por criterio, máximo 20 puntos)

Criterio	Descripción	Guía de puntuación
Centro tonal	La música tiene una nota de reposo perceptible y estable	1: ningún CT; 2: atisbo de tónica, muy inestable; 3: CT intermitente pero identificable; 4: CT claro con alguna desviación; 5: CT claro y sostenido
Color modal	La sonoridad refleja el modo objetivo (p. ej. la 6ª mayor en dórico)	1: ningún rasgo modal; 2: algún rasgo aislado, difuso; 3: algún rasgo pero ambiguo; 4: color modal reconocible aunque no sistemático; 5: color modal claramente identificable
No modulación	La pieza se mantiene en el modo objetivo sin cambiar de tonalidad	1: modulaciones frecuentes o graves; 2: varias desviaciones o una grave; 3: alguna desviación puntual; 4: muy estable con deslizamientos breves; 5: sin modulaciones apreciables
Coherencia musical	La música es musicalmente coherente y escuchable (timbre, ritmo, estructura)	1: muy degradada o incoherente; 2: degradación notable, escuchabilidad limitada; 3: aceptable con partes irregulares; 4: fluida, algo inferior al modelo base; 5: fluida y comparable al modelo base

La evaluación se realizó sobre audios de 20–30 segundos generados con semilla fija (1111 y 2222), escuchados sin conocimiento previo del checkpoint ni de la configuración correspondiente, con el único dato del modo objetivo. Las puntuaciones se registraron en una hoja de cálculo estructurada y se promediaron por modo y por checkpoint para construir el ranking final de candidatos.

Este diseño metodológico, al combinar cribado automático y verificación musical informada, reduce el coste de evaluación sin renunciar a la interpretación musical de los resultados.

4. Resultados y discusión

4.1. Resumen de resultados actuales

Los experimentos muestran una mejora clara frente a configuraciones iniciales inestables, alcanzando control modal parcial con buena calidad musical general. Se observa un comportamiento más robusto en varios modos y una mayor coherencia global en los mejores checkpoints.

La estrategia de selección se realizó en dos fases: primero, ranking determinista de checkpoints; después, evaluación manual de los candidatos más prometedores. Esta combinación permitió reducir de forma significativa el número de audios a evaluar sin perder trazabilidad experimental.

El estudio incluye además una comparativa entre prompts detallados y prompts mínimos, así como una verificación metodológica de la herramienta de inferencia por lotes para asegurar que la diferencia observada procede del contenido del prompt y no de errores de parseo.

4.2. Resultados automáticos de la fase de validación

La Tabla 4.1 resume los resultados automáticos más relevantes obtenidos en la fase de validación.

Tabla 4.1. Resumen de resultados automáticos recientes

Experimento	Score (0–1)	Acc. modal	Observación
run_D (completo)	0.711	85.7 %	Control modal parcial con margen de mejora
B (detailed, smoke)	0.7329	85.7 %	Referencia para comparativa de prompts
E (mode-only, smoke)	0.7350	85.7 %	Diferencia pequeña pero real frente a B

El resultado más importante de esta tabla no es la magnitud de la mejora entre B y E, sino la validación del procedimiento experimental: tras corregir el parseo de bloques, la comparativa dejó de ser idéntica y pasó a reflejar diferencias medibles. El estudio detallado de estas diferencias, incluyendo una tercera variante de prompt minimalista, se desarrolla en la Sección 4.10.

4.3. Resultados de la búsqueda sistemática de hiperparámetros

Los 24 experimentos de la búsqueda de hiperparámetros finalizaron con éxito. La Tabla 4.2 recoge los diez mejores ordenados por `auto_score_0_1`.

Tabla 4.2. Top 10 configuraciones de la búsqueda de hiperparámetros por `auto_score_0_1`

Exp.	Rank	Alpha	LR	Dropout	Score
1	32	32	10^{-4}	0.05	0.7244
2	32	32	10^{-4}	0.10	0.7244
9	64	32	10^{-4}	0.05	0.7243
18	128	32	10^{-4}	0.10	0.7241
10	64	32	10^{-4}	0.10	0.7241
17	128	32	10^{-4}	0.05	0.7240
21	128	128	10^{-4}	0.05	0.7207
6	32	128	10^{-4}	0.10	0.7203
22	128	128	10^{-4}	0.10	0.7203
5	32	128	10^{-4}	0.05	0.7202

El factor más determinante es la tasa de aprendizaje: los 12 experimentos con $lr = 10^{-4}$ superan a todos los de $lr = 10^{-3}$, sin excepción. La Figura 4.1 ilustra los 24 experimentos ordenados por `auto_score_0_1` y coloreados por tasa de aprendizaje, evidenciando la separación completa entre ambos grupos. La Tabla 4.3 cuantifica esta sensibilidad.




Figura 4.1. Los 24 experimentos de la búsqueda de hiperparámetros ordenados por `auto_score_0_1`. En azul, los experimentos con $lr = 10^{-4}$; en rojo, los de $lr = 10^{-3}$. La línea discontinua marca el punto de corte entre ambos grupos. El experimento 19 (rayado) presenta duración anómala. Los 12 experimentos con $lr = 10^{-4}$ ocupan las 12 primeras posiciones sin excepción.

Tabla 4.3. Sensibilidad de `auto_score_0_1` a cada hiperparámetro

Hiperparámetro	Valor	Media	Desv. típ.	Efecto (Δ)
Learning rate	10^{-4}	0.7217	0.0029	+0.029
	10^{-3}	0.6932	0.0103	
Alpha	32	0.7114	0.0140	+0.008
	128	0.7035	0.0181	
Rank	32	0.7066	0.0198	< 0,001
	64	0.7095	0.0128	
	128	0.7062	0.0178	
Dropout	0.05	0.7076	0.0163	< 0,001
	0.10	0.7072	0.0172	

Además, los experimentos con $lr = 10^{-3}$ presentan una variabilidad 3,5 veces mayor (desv. típ. 0.0103 frente a 0.0029), lo que indica menor robustez de entrenamiento. Rank y dropout son prácticamente irrelevantes en este contexto.

Las Figuras 4.2 y 4.3 ilustran visualmente estos resultados.




Figura 4.2. Mapa de calor de `auto_score_0_1` en función de rank y alpha (media sobre lr y dropout). Los valores más altos se concentran en $\alpha = 32$ independientemente del rank.




Figura 4.3. Sensibilidad de auto_score_0_1 a la tasa de aprendizaje. La diferencia entre 10^{-4} y 10^{-3} es la mayor observada entre todos los hiperparámetros explorados.




Figura 4.4. Sensibilidad de auto_score_0_1 al parámetro alpha. Alpha = 32 supera consistentemente a alpha = 128, especialmente en combinación con $lr = 10^{-4}$.

Se detectó una anomalía en el experimento 19 (rank = 128, alpha = 32, $lr = 10^{-3}$, dropout = 0.05): su duración de entrenamiento fue 800 s frente a los ~5400 s del resto, lo que sugiere una interrupción y reinicio parcial. El experimento alcanzó epoch 140 y su score (0.705) es coherente con el grupo $lr = 10^{-3}$; se mantiene en el análisis como dato válido con esta advertencia.

4.4. Evaluación manual de la búsqueda de hiperparámetros

Se evaluó auditivamente un subconjunto de checkpoints de los cinco experimentos con mejor ranking automático de la búsqueda, cubriendo dos epochs por experimento. La Tabla 4.4 recoge los promedios obtenidos.

Tabla 4.4. Resultados de la evaluación manual de la búsqueda de hiperparámetros (escala 0–20, 4 criterios)

Exp.	Config.	Epoch	Score	Jónico	Eólico
Exp_01	r32, α 32, lr= 10^{-4} , do=0.05	80	8.48	7.63	12.63
Exp_02	r32, α 32, lr= 10^{-4} , do=0.10	80	8.48	8.25	12.63
Exp_09	r64, α 32, lr= 10^{-4} , do=0.05	60	8.66	7.13	13.00
Exp_10	r64, α 32, lr= 10^{-4} , do=0.10	60	8.70	8.00	11.63
Exp_18	r128, α32, lr= 10^{-4}, do=0.10	120	9.89	12.13	12.25

De estos resultados se extraen dos hallazgos metodológicos relevantes.

El epoch óptimo no es el checkpoint final. El protocolo de búsqueda evaluó automáticamente epoch 140 para todos los experimentos. Sin embargo, Exp_18 alcanza su mejor resultado en epoch 120 (9.89/20), y Exp_09/10 pican en epoch 60 y caen en epoch 80. El uso sistemático del checkpoint final infravalora configuraciones que convergen antes, lo que constituye una limitación del protocolo de evaluación automática empleado.

El ranking automático no predice el mejor resultado perceptivo. Exp_01 obtiene el mayor `auto_score_0_1` de toda la búsqueda (0.7244), pero solo 8.48/20 en evaluación manual. Exp_18, cuarto en el ranking automático (0.7241, diferencia de apenas 0.0003), es el mejor perceptivamente con 9.89/20. Una diferencia de 0.0003 en la métrica automática oculta 1.4 puntos de distancia en calidad auditiva real. Este resultado refuerza la necesidad del enfoque de evaluación dual: la métrica automática es útil para cribar el espacio de configuraciones, pero no puede sustituir a la escucha informada para determinar el mejor checkpoint.

La Figura 4.5 visualiza esta inversión comparando la posición de cada experimento en ambos rankings: Exp_01 ocupa el primer puesto en el ranking automático pero el último en el manual, mientras que Exp_18 hace el camino inverso.




Figura 4.5. Posición de los cinco experimentos mejor puntuados automáticamente en el ranking automático (azul oscuro) y en el ranking de evaluación manual (azul claro). La barra más corta indica mejor posición (1 = mejor). Exp_01 lidera el ranking automático pero queda último en el manual; Exp_18 ocupa la cuarta posición automática pero la primera en escucha informada. Se incluyen los valores reales de `auto_score_0_1` y la puntuación manual para referencia.

Durante la escucha se observó además un patrón de confusión específico de las configuraciones de la búsqueda que no aparecía en `run_D`: varios audios pedidos como eólico (menor natural) incluían de forma prominente la 2ª disminuida, que es la nota característica del frigio. Es decir, el modelo confunde un modo menor con otro modo menor distinto, en lugar de simplemente caer al mayor como en `run_D`. Esta confusión entre modos menores cercanos sugiere que la señal de condicionamiento modal en estas configuraciones es menos nítida (probablemente por la combinación de una tasa de aprendizaje más alta, 10^{-4} frente a $5 \cdot 10^{-5}$ de `run_D`, y un número distinto de épocas evaluadas).

4.5. Experimento de confirmación

A partir de los resultados de la búsqueda sistemática de hiperparámetros, que identificó $lr = 10^{-4}$ y $\alpha = 32$ como configuración dominante, se realizó un experimento de confirmación con esa configuración óptima ($r = 32$, $\alpha = 32$, $lr = 10^{-4}$, dropout = 0.05) para verificar si los resultados automáticos se traducen en mejora perceptiva real frente al checkpoint de referencia run_D.

La evaluación manual del experimento de confirmación se realizó con los mismos cuatro criterios que el resto del estudio (centro tonal, color modal, no modulación y coherencia, escala 0–20). La Tabla 4.5 recoge la comparativa directa por modo frente a run_D.

Tabla 4.5. Comparativa directa entre run_D y el experimento de confirmación (epoch 140, escala 0–20)

Modo	run_D (/20)	run_D %	Confirmación (/20)	Confirm. %
Jónico	17.75	89 %	16.25	81 %
Dórico	11.75	59 %	14.13	71 %
Frigio	11.00	55 %	9.38	47 %
Lidio	15.50	78 %	11.00	55 %
Mixolidio	12.00	60 %	10.50	53 %
Eólico	11.38	57 %	10.00	50 %
Locrio	7.50	38 %	6.63	33 %
Global	12.41/20	62 %	11.14/20	56 %

El experimento de confirmación no mejora el resultado global de run_D (56 % frente a 62 %), pero logra el objetivo específico para el que fue diseñado: reducir el sesgo hacia sonoridades mayores en los modos menores. El hallazgo más relevante es la mejora en modo dórico (+12 pp): run_D alcanzaba un 59 % en ese modo con tendencia sistemática a generar D mayor en lugar de D menor, mientras que el experimento de confirmación alcanza un 71 %, con ejemplos donde el carácter dórico es claramente perceptible (6ª mayor prominente, variaciones armónicas características del modo). Ésta es la primera configuración del estudio que produce ejemplos dóricos reconocibles de forma consistente.

Esta mejora tiene un coste: la capacidad del adaptador se redistribuye hacia los modos menores, lo que reduce ligeramente el rendimiento en modos mayores ya bien dominados por el modelo base, especialmente en lidio (−23 pp) y jónico (−8 pp).

La Figura 4.6 visualiza la comparativa completa por modo, ilustrando tanto el patrón general de

retroceso de la configuración de confirmación como la excepción notable en dórico.




Figura 4.6. Comparativa de la evaluación manual por modo entre run_D y el experimento de confirmación. Las barras representan el porcentaje del máximo de 20 puntos. La línea discontinua marca el promedio global de run_D (62 %). El modo dórico (naranja) es el único con mejora significativa (+12 pp); el resto retrocede entre 5 y 23 puntos porcentuales.

4.6. Análisis cualitativo por modo

Más allá de los valores numéricos, la evaluación auditiva permitió identificar patrones cualitativos consistentes en cómo el modelo trata cada modo. Este análisis complementa la tabla de resultados con observaciones sobre el tipo de error más frecuente, la nota característica que el modelo tiende a ignorar y el nivel de consistencia perceptiva dentro de cada modo.

Jónico (89 % en run_D). Es el modo mejor controlado del estudio, lo que refleja el sesgo del modelo base hacia sonoridades mayores. La tónica se establece con claridad desde los primeros compases, las progresiones armónicas son coherentes y la calidad tímbrica es alta. El riesgo principal es el opuesto: el modelo puede generar jónico cuando se le pide otro modo mayor (lidio o mixolidio), diluyendo la separabilidad entre ellos.

Dórico (59 % en run_D; 71 % en confirmación). Es el modo que experimenta la mejora más significativa del estudio (+12 pp). El problema central en run_D es que el modelo genera D menor natural en lugar de D dórico: omite sistemáticamente la 6ª mayor ($\text{Si}\sharp$) y produce la 6ª menor ($\text{Si}\flat$), que es la nota característica del eólico. Con la configuración de confirmación aparecen por primera vez fragmentos donde el $\text{Si}\sharp$ es claramente audible, con progresiones armónicas que incluyen acordes de II mayor o VI mayor, rasgos armónicos distintivos del dórico en jazz.

Frigio (55 % en run_D). El modo frigio presenta el reto de la 2ª disminuida sobre la tónica, que en el caso de E frigio implica usar Fa♯ sobre Mi. El modelo tiende a evitar este intervalo y genera la 2ª mayor (Fa♯), aproximando la salida a E menor natural. Cuando aparecen rasgos frigios, lo hacen de forma puntual —en una frase o en la cadencia— pero sin mantenerse durante toda la pieza. El estilo flamenco o árabe que caracteriza al frigio no emerge de forma consistente en ninguna configuración evaluada.

Lidio (78 % en run_D). Junto al jónico, es el modo con mejor resultado en run_D. La 4ª aumentada (Si♯ en F lidio) aparece con frecuencia en las melodías, y el carácter etéreo o flotante del modo es perceptible. El retroceso en confirmación (−23 pp) se interpreta como un efecto de la menor capacidad del adaptador ($r = 32$ frente a $r = 64$) para mantener la separabilidad en modos que requieren diferenciación espectral más fina respecto al mayor natural.

Mixolidio (60 % en run_D). El modo mixolidio se diferencia del jónico únicamente por la 7ª menor. El modelo casi nunca introduce esa nota de forma prominente: las salidas etiquetadas como mixolidio suenan en su mayoría a mayor natural, con la 7ª apareciendo ocasionalmente en pasajes de relleno armónico. El carácter bluesy o celta que define al mixolidio —donde la 7ª menor crea tensión sobre el acorde de tónica— rara vez emerge de forma convincente.

Eólico (57 % en run_D). El menor natural es el modo al que el modelo parece recurrir como *default* cuando se le pide una sonoridad oscura. Las salidas son funcionalmente correctas como música en menor, pero carecen de diferenciación clara respecto al dórico o el frigio: la 6ª puede ser mayor o menor según la frase, y la 7ª no siempre es la mayor esperada. El modo eólico obtiene resultados aceptables precisamente porque es el modo menor más neutro, no porque el modelo lo controle con precisión.

Locrio (38 % en run_D). Es el modo más difícil de controlar y el que peores resultados obtiene en todas las configuraciones evaluadas. El tritono entre la tónica y la quinta disminuida genera una inestabilidad armónica tan acusada que el modelo tiende a resolver de inmediato hacia otra tonalidad: las escuchas revelan que la música empieza en un contexto ambiguo pero termina estabilizándose en B mayor, E mayor o incluso A menor, sin mantener en ningún momento el centro tonal en Si. Este comportamiento es coherente con la práctica habitual en música popular, donde locrio casi nunca se sostiene durante más de unos pocos acordes. El experimento de confirmación obtiene 0.705 frente a 0.711 de run_D, un nuevo caso donde `auto_score_0_1` infravalora mejoras perceptivas en modos menores con carácter modal sutil. Esto refuerza la necesidad de evaluación dual.

4.7. Análisis por modo del checkpoint de referencia run_D

Tomando como referencia la mejor configuración de la fase exploratoria (r64-a128-d0.05-lr5e-5, epoch 100, run_D), la Tabla 4.6 recoge la media por modo sobre la escala de evaluación manual (0–20). Esta tabla establece la línea de referencia que el experimento de confirmación (Sección 4.5) toma como punto de partida para reducir el sesgo en modos menores.

Tabla 4.6. Media por modo en el checkpoint de referencia run_D ($r = 64$, $\alpha = 128$, $lr = 5 \cdot 10^{-5}$, epoch 100)

Modo	Media	Interpretación
Jónico	17.75	Muy buen control y coherencia global
Lidio	15.50	Buen control modal con ejemplos destacados
Mixolidio	12.00	Control parcial, confusión ocasional con sonoridad mayor natural
Dórico	11.75	Color modal parcial, tendencia a resolver en mayor
Frigio	11.00	Rasgos parciales, inestabilidad en sonoridad menor
Eólico	11.38	Resultado funcional pero poco consistente en color modal
Locrio	7.50	Modo menos robusto e inestable

El patrón observado es coherente con las escuchas: el modelo responde mejor en modos con sonoridad más estable y presenta más dificultad en modos con mayor tensión armónica, especialmente en locrio y en parte de los modos menores.

4.8. Análisis de tasas de éxito por umbral

Las tablas presentadas hasta ahora resumen la evaluación manual mediante **promedios** por configuración y por modo. Esta forma de agregación es útil para comparar tendencias globales, pero presenta una limitación conocida: un mismo promedio puede corresponder a distribuciones muy distintas. Una puntuación media de 2.5 sobre 5 puede surgir de un conjunto de audios homogéneamente mediocres o de una mezcla de audios excelentes con otros muy débiles. Para distinguir entre ambos casos se introduce un segundo punto de vista, complementario al promedio, basado en **tasas de éxito por umbral**.

Para cada audio y criterio de la rúbrica se define un umbral binario:

- **Umbral permisivo** (≥ 2 en escala 1–5, equivalente a ≥ 10 en el total 0–20). Marca aquellos audios en los que el modelo muestra *algo* del rasgo evaluado, más allá del rango “ningún rasgo” descrito en la rúbrica.
- **Umbral estricto** (≥ 3 en escala 1–5, equivalente a ≥ 12 en el total 0–20). Marca audios en los que el rasgo evaluado está presente de forma reconocible, aunque aún sea ambigua.

A partir de estos umbrales se calcula, por cada configuración **Run + Checkpoint**, el porcentaje de audios que superan cada nivel. La elección de dos umbrales en paralelo evita comprometerse con un corte arbitrario único y permite distinguir configuraciones donde el modelo *acierta de forma consistente* de aquellas donde simplemente *no falla del todo*.

4.8.1. Ranking por criterio

La Figura 4.7 muestra el top 10 de configuraciones por tasa de éxito en **color modal**, el criterio más directamente alineado con el objetivo del proyecto. Las dos barras agrupadas por configuración permiten leer simultáneamente cuántos audios superan el umbral permisivo (alguna traza modal) y cuántos superan el estricto (rasgo modal reconocible).




Figura 4.7. Top 10 de configuraciones por porcentaje de audios que superan el umbral en **color modal**. Se muestran lado a lado el umbral permisivo (≥ 2) y el estricto (≥ 3).

La lectura es directa. **r128_a256_d005** en su checkpoint temprano lidera el ranking estricto con un 57.1 % de audios reconocibles, seguido por la variante **Prompt solo modo** con 42.9 % y un grupo de tres configuraciones empatadas a 35.7 % que incluye los dos checkpoints del experimento de confirmación (epoch 140 y epoch 160). El experimento de confirmación no domina el ranking global, sino que se sitúa en la zona media del top 10. Este resultado es coherente con el diseño del experimento: la configuración se eligió para atacar el sesgo en modos menores específicos, no para maximizar el promedio sobre los siete modos.

Las figuras correspondientes para el resto de criterios (centro tonal, no modulación y coherencia) y para el total agregado se presentan en el Apéndice B (figuras B.1 a B.4). El patrón global se sintetiza en el mapa de calor de la Figura 4.8, que permite leer de un vistazo qué configuraciones destacan en cada criterio.




Figura 4.8. Mapa de calor del porcentaje de éxito estricto (≥ 3 en criterios 1–5; ≥ 12 en total 0–20) para las diez configuraciones con mejor promedio. Cada columna corresponde a un criterio de la rúbrica más el total agregado.

4.8.2. Lectura por modo: el caso del dórico

El ranking global por configuración enmascara una observación crítica para la interpretación del experimento de confirmación. Cuando el cálculo se realiza por Run + Checkpoint + Modo, el experimento de confirmación `confirm_r32_a32_lr1e-4` alcanza el **100 % de éxito estricto en color modal sobre los audios dóricos**, en sus dos checkpoints evaluados (epoch 140 y epoch 160). Esta es la única configuración del estudio que produce dos de dos audios dóricos con color modal reconocible, frente al 0 % que obtienen tanto `run_D` como la mayoría de configuraciones de la búsqueda en ese mismo modo.

Esta lectura no contradice el promedio mostrado en la Tabla 4.5 —donde el confirm queda por debajo de `run_D` en el global— sino que la complementa: lo que el promedio describe como “ligero retroceso global con mejora en dórico” se traduce, en términos de tasa de éxito, en “el confirm es la única configuración capaz de superar el umbral estricto en todos sus audios dóricos”. La diferencia entre ambos puntos de vista ilustra el valor de presentar el resultado en dos formas: el promedio cuantifica la distancia, la tasa binaria cuantifica la consistencia.

En el extremo opuesto, el modo locrio ofrece la lectura más severa: ninguna configuración del estudio supera el 0 % de éxito estricto sobre los audios locrios, lo que refuerza numéricamente la observación cualitativa de que este modo permanece sin control efectivo en todas las configuraciones evaluadas.

4.8.3. Interpretación

La introducción de tasas de éxito por umbral aporta tres elementos a la discusión:

1. **Separa consistencia de magnitud.** El promedio premia configuraciones con muchos audios moderadamente buenos; la tasa estricta premia configuraciones que producen aciertos claros aunque sean menos. Ambos puntos de vista son legítimos y describen propiedades distintas de un mismo conjunto de resultados.
2. **Refuerza la metodología de evaluación dual.** El cribado automático determinista filtra el espacio de configuraciones; la rúbrica manual con promedio describe tendencias; la lectura por umbral cuantifica la fiabilidad. Las tres capas son complementarias y reflejan decisiones independientes.
3. **Soporta la conclusión del experimento de confirmación con evidencia binaria.** El hallazgo de que el confirm produce el 100 % de audios dóricos con color modal reconocible es un resultado más fuerte que la simple mejora de promedio, ya que no depende de una diferencia numérica pequeña sino de una propiedad cualitativa sin contraejemplo.

Las observaciones del análisis cualitativo del párrafo anterior y de la sección 4.6 encuentran aquí un soporte cuantitativo binario que las hace más compactas de comunicar al lector.

4.9. Patrón de confusión mayor/menor

El análisis cualitativo de las escuchas revela un sesgo sistemático y recurrente: el modelo tiende a generar los modos menores (dórico, frigio, eólico) en su relativo o paralelo mayor. Este comportamiento aparece de forma consistente en todos los runs evaluados y no se corrige con mayor número de epochs dentro del rango explorado.

La Tabla 4.7 documenta las confusiones más frecuentes observadas durante la evaluación manual.

Tabla 4.7. Confusiones recurrentes entre modo objetivo y modo generado

Modo objetivo	Generado	Observación típica
Dórico (D menor)	D mayor	“No aprende que el dórico es un modo menor”
Frigio (E menor)	E mayor	“No capta el menor; suena la 7ª mayor”
Mixolidio (G mix.)	G mayor natural	“No mete la 7ª menor en ningún momento”
Eólico (A menor)	A menor (parcial)	“Falta la 6ª menor característica”
Locrio (B loc.)	B/E mayor	“No consolida la raíz en B; muy inestable”

Este patrón sugiere que el modelo base de ACE-Step tiene un sesgo inherente hacia sonoridades mayores y resoluciones tonales estables, que la adaptación LoRA no logra revertir completamente con el dataset y configuración actuales. La implicación práctica es que mejorar el control en modos menores requeriría bien aumentar la proporción de ejemplos de entrenamiento en esos modos, bien utilizar una señal de condicionamiento más explícita que distinga activamente entre modo mayor y menor.

4.10. Ablación de variantes de prompt

Sobre el mismo checkpoint base (epoch 100, run_D), se evaluó el efecto de tres variantes de prompt para aislar la contribución del condicionamiento textual:

- **Bloque B (detallado):** descripción modal completa con tónica, carácter armónico y contexto de jazz-fusión.
- **Bloque modo+instrumento:** nombre del modo con instrumentación, sin tónica explícita.
- **Bloque modo solo:** únicamente el nombre del modo.

A modo de ilustración, los tres prompts para el modo dórico son:

B (detallado): dorian mode, jazz-fusion instrumental, D dorian, electric piano lead, fretless bass, brushed drums, 96 BPM, minor with hopeful color, natural 6th flavor, stable tonic on D, no modulation, no vocals

Modo+instrumento:dorian mode, instrumental, electric piano, fretless bass, brushed drums, no vocals

Modo solo: dorian mode

La Tabla 4.8 recoge los promedios globales y el valor por modo en dórico, donde la diferencia es más pronunciada.

Tabla 4.8. Comparativa de variantes de prompt sobre el mismo checkpoint (epoch 100)

Variante de prompt	Promedio global	Dórico	Jónico
B (detallado)	10.48	9.00	17.38
Modo + instrumento	10.52	7.75	16.50
Modo solo	10.79	9.75	16.25

El prompt más minimalista (*modo solo*) supera a los más detallados en promedio global y especialmente en dórico. Esto sugiere que el condicionamiento textual excesivo puede interferir con la señal modal aprendida por el adaptador, posiblemente porque el modelo base ya resuelve bien ciertos aspectos musicales a partir de pocas palabras clave. Este resultado es relevante para RQ3: la evaluación reproducible del control modal no debe asumir que más contexto textual implica mejor resultado.

4.11. Comparativa global de configuraciones

Una vez analizados individualmente la fase exploratoria, la búsqueda sistemática y el experimento de confirmación, la Tabla 4.9 sintetiza el comportamiento medio de las configuraciones más representativas evaluadas a lo largo del estudio. Los valores corresponden a la media global de la rúbrica manual para los checkpoints más representativos de cada configuración.

Tabla 4.9. Comparativa resumida de configuraciones LoRA evaluadas

Configuración	Checkpoint	Media	Observación
r128-a256-d0.05	epoch 20	10.79	Calidad aceptable inicial, inestable en modos
r128-a256-d0.05	epoch 100	5.82	Degradación fuerte (sobreentrenamiento)
r64-a128-d0	epoch 80	9.57	Resultado medio, control modal parcial
r64-a128-d0	epoch 180	9.29	Estancamiento respecto a checkpoints previos
r64-a128-d0.05	epoch 160	5.09	Configuración descartada por baja calidad
r64-a128-d0.05-lr5e-5	epoch 100	12.41	Configuración de referencia (run_D)
r64-a128-d0.05-lr5e-5	epoch 140	9.96	Caída respecto al mejor checkpoint
r64-a128-d0.05-lr5e-5	epoch 160	10.34	Recuperación parcial, inferior a epoch 100
confirm-r32-a32-lr1e-4*	epoch 140	11.14	Mejor resultado en modos menores; ver Sección 4.5

* Escala 0–20 (4 criterios). Equivale a 55.7 % del máximo frente al 62.1 % de run_D (ambos sobre 20). Mejora en dórico: +12 pp.

Esta comparativa sugiere dos conclusiones relevantes: (i) aumentar capacidad (r y α altos) no garantiza mejor control modal sostenido y puede degradar resultados; (ii) la configuración más equilibrada de la fase exploratoria es run_D, pero el experimento de confirmación derivado de la búsqueda sistemática reduce de forma específica el sesgo en modos menores —especialmente en dórico— a costa de un ligero retroceso global.

4.12. Hallazgos principales

El resultado más relevante es que el condicionamiento modal mediante LoRA es viable sobre ACE-Step 1.5 sin reentrenar el modelo completo. No obstante, persiste una limitación en la consolidación de ciertos modos menores, que en algunos casos tienden a confundirse con sonoridades más estables de tipo mayor.

Este comportamiento sugiere que el principal reto ya no es la calidad tímbrica, sino la separación armónica fina entre modos cercanos. Por tanto, los siguientes ciclos experimentales deben priorizarse en esa dirección y no en aumentar complejidad superficial de prompts.

Como consecuencia práctica, los hallazgos de la búsqueda de hiperparámetros orientaron directamente un experimento de confirmación con $lr = 10^{-4}$, $\alpha = 32$ y $r = 32$. Este experimento no supera a run_D en el resultado global (56 % frente a 62 %), pero valida su objetivo específico: reducir el sesgo en modo dórico (+12 puntos porcentuales, de 59 % a 71 %), siendo la primera configuración del estudio que produce ejemplos dóricos reconocibles de forma consistente. El ciclo experimental queda así cerrado: búsqueda sistemática, identificación de configuración óptima para el modo problemático y validación empírica focalizada.

4.13. Respuesta a las preguntas de investigación

Con la evidencia disponible en esta fase del proyecto, puede responderse de forma provisional a las preguntas planteadas en la introducción:

- **RQ1:** Sí, LoRA permite mejorar control modal manteniendo calidad global razonable, aunque el efecto no es homogéneo en todos los modos.
- **RQ2:** La búsqueda sistemática identifica $lr = 10^{-4}$ y $\alpha = 32$ como configuración dominante. Un experimento de confirmación posterior valida el objetivo específico de esa configuración: reducir el sesgo en modo dórico (+12 pp, de 59 % a 71 %), siendo el primer resultado del estudio con ejemplos dóricos reconocibles de forma consistente, aunque el promedio global desciende ligeramente (56 % frente a 62 % de run_D). El ciclo completo —búsqueda → identificación → confirmación— demuestra la utilidad práctica de la metodología propuesta.
- **RQ3:** Una evaluación reproducible para modalidad requiere enfoque dual; las métricas automáticas son útiles para cribar, pero insuficientes sin validación auditiva estructurada.

4.14. Validez y limitaciones

Entre las principales limitaciones del estudio destacan el tamaño reducido del dataset y su desbalance entre clases. Además, la evaluación humana, aunque estructurada, mantiene una componente subjetiva: las puntuaciones de la rúbrica fueron asignadas por un único evaluador (el

autor de este trabajo), por lo que no se dispone de medida de acuerdo inter-evaluadores. Esto debe tenerse en cuenta al interpretar diferencias pequeñas entre configuraciones.

Otra limitación de carácter estadístico es la búsqueda sistemática de hiperparámetros: cada configuración se evaluó con $n = 2$ semillas por modo (1111 y 2222), un número suficiente para detectar efectos grandes (como el de la tasa de aprendizaje, $\Delta = 0,029$) pero insuficiente para distinguir con confianza diferencias inferiores a ~ 0.005 en `auto_score_0_1`. Las primeras posiciones del ranking de la Tabla 4.2, separadas por décimas de milésima, deben interpretarse como un grupo de configuraciones equivalentes más que como un orden estricto.

Como punto fuerte, el protocolo seguido es reproducible y permite tomar decisiones experimentales con criterios explícitos.

Otra limitación relevante es que la evaluación auditiva exige mucho tiempo cuando se comparan muchos checkpoints y semillas. Para mitigarlo, el flujo adoptado combina filtrado automático determinista y evaluación manual focalizada en candidatos, lo que mejora la eficiencia sin perder control metodológico.

Respecto al dataset, los 102 clips se obtuvieron a partir de fragmentos cortos (20–50 s) de obras musicales existentes, seleccionados manualmente con fines exclusivamente académicos y de investigación. El material no se incluye en el repositorio público¹ por restricciones de derechos de autor, lo que constituye una limitación de reproducibilidad externa que se asume explícitamente. El script de preparación del dataset (`scripts/prepare_modes_dataset.py`) está disponible en el repositorio y documenta el proceso de selección y etiquetado para quien desee replicarlo con fuentes propias.

¹<https://github.com/nachofrancoalm-dot/ACE-Step-1.5-LoRA-modal-music>

5. Conclusiones y trabajo futuro

5.1. Conclusiones

Se concluye que:

1. La adaptación LoRA sobre ACE-Step 1.5 permite introducir control modal sin reentrenamiento completo, con coste computacional razonable para iteración académica.
2. La búsqueda sistemática de hiperparámetros (24 experimentos) identifica la tasa de aprendizaje como el hiperparámetro más crítico ($\Delta = 0,029$ en `auto_score_0_1`), con $lr = 10^{-4}$ y $\alpha = 32$ como configuración dominante. Un experimento de confirmación posterior valida esta elección: aunque el resultado global desciende ligeramente (56 % frente a 62 % de `run_D`), se logra por primera vez control dórico reconocible de forma consistente (+12 puntos porcentuales en ese modo, de 59 % a 71 %).
3. El reto técnico principal no es la calidad sonora —que se mantiene en niveles aceptables en todas las configuraciones— sino la separación robusta entre modos cercanos, en particular entre modos menores y sus relativos mayores. El experimento de confirmación atenúa parcialmente este sesgo, aunque no lo elimina.

En conjunto, los objetivos del proyecto se consideran alcanzados: se ha establecido una metodología experimental completa y reproducible, se han identificado las configuraciones LoRA más prometedoras mediante búsqueda sistemática, y se ha validado empíricamente que la configuración óptima reduce de forma medible el sesgo en modos menores, con avances especialmente significativos en el modo dórico (+12 pp en evaluación perceptiva). El análisis complementario por tasa de éxito por umbral (sección 4.8) refuerza esta conclusión con evidencia binaria: el experimento de confirmación es la única configuración del estudio que produce el 100 % de audios dóricos con color modal reconocible bajo el umbral estricto, mientras que en el ranking global se mantiene en posiciones intermedias, coherente con su diseño focalizado.

Como cierre, la principal aportación del trabajo no es solo una configuración concreta, sino un procedimiento experimental replicable para estudiar control armónico en modelos generativos musicales con recursos acotados.

5.2. Trabajo futuro

Como líneas de continuación se plantean:

- Extender el experimento de confirmación a más configuraciones de rank y a mayor número de epochs, evaluando checkpoints intermedios para identificar el punto óptimo de convergencia de forma más precisa.
- Mejorar el balance del dataset en modos menos representados para reducir sesgos de aprendizaje modal.
- Refinar la estrategia de etiquetado modal conservador para aumentar separabilidad entre modos sin forzar características ajenas al contenido real de los clips.
- Incorporar métricas automáticas complementarias para reducir carga de evaluación manual y facilitar escalado experimental.
- Validar resultados en más semillas y escenarios de inferencia para estimar robustez fuera del conjunto de pruebas principal.
- Extender la evaluación manual de la búsqueda de hiperparámetros al resto de experimentos no evaluados, para completar la validación auditiva del ranking automático más allá de los cinco experimentos cubiertos (Exp_01, Exp_02, Exp_09, Exp_10, Exp_18).
- Diseñar estrategias específicas para modos menores (dórico, frigio) que contrarresten el sesgo hacia sonoridades mayores identificado en la evaluación manual, como sobrerepresentación de esos modos en el dataset o refuerzo explícito de la nota característica en los captions.

A. Resultados completos de la búsqueda de hiperparámetros

La Tabla [A.1](#) recoge los 24 experimentos de la búsqueda sistemática de hiperparámetros, ordenados por identificador. El experimento 19 presenta una duración de entrenamiento anómala (800 s frente a ~ 5400 s del resto); véase la discusión en el capítulo de resultados.

Tabla A.1. Resultados completos de la búsqueda de hiperparámetros (24 experimentos, epoch 140)

Exp.	Rank	Alpha	LR	do	Score	Acc. modal	Est. tonal
1	32	32	10^{-4}	0.05	0.7244	0.7416	0.8932
2	32	32	10^{-4}	0.10	0.7244	0.7416	0.8932
3	32	32	10^{-3}	0.05	0.7053	0.7148	0.8872
4	32	32	10^{-3}	0.10	0.7029	0.7134	0.8807
5	32	128	10^{-4}	0.05	0.7202	0.7344	0.8936
6	32	128	10^{-4}	0.10	0.7203	0.7346	0.8940
7	32	128	10^{-3}	0.05	0.6815	0.6777	0.8874
8	32	128	10^{-3}	0.10	0.6737	0.6754	0.8639
9	64	32	10^{-4}	0.05	0.7243	0.7418	0.8896
10	64	32	10^{-4}	0.10	0.7241	0.7417	0.8891
11	64	32	10^{-3}	0.05	0.6890	0.6944	0.8789
12	64	32	10^{-3}	0.10	0.7020	0.7106	0.8869
13	64	128	10^{-4}	0.05	0.7165	0.7308	0.8855
14	64	128	10^{-4}	0.10	0.7170	0.7313	0.8859
15	64	128	10^{-3}	0.05	0.7026	0.7108	0.8928
16	64	128	10^{-3}	0.10	0.7002	0.7111	0.8813
17	128	32	10^{-4}	0.05	0.7240	0.7428	0.8889
18	128	32	10^{-4}	0.10	0.7241	0.7429	0.8873
19*	128	32	10^{-3}	0.05	0.6981	0.7058	0.8828
20	128	32	10^{-3}	0.10	0.6940	0.6994	0.8844
21	128	128	10^{-4}	0.05	0.7207	0.7353	0.8902
22	128	128	10^{-4}	0.10	0.7203	0.7350	0.8904
23	128	128	10^{-3}	0.05	0.6848	0.6895	0.8716
24	128	128	10^{-3}	0.10	0.6839	0.6894	0.8623

* Duración anómala: 800 s frente a ~ 5400 s del resto.

B. Rankings completos por tasa de éxito

Este apéndice recoge las figuras complementarias a la sección 4.8, mostrando el top 10 de configuraciones por tasa de éxito en los criterios de la rúbrica no incluidos en el cuerpo principal del capítulo, así como en la puntuación total agregada.




Figura B.1. Top 10 de configuraciones por porcentaje de éxito en **centro tonal**.




Figura B.2. Top 10 de configuraciones por porcentaje de éxito en **no modulación**.




Figura B.3. Top 10 de configuraciones por porcentaje de éxito en **coherencia musical**.




Figura B.4. Top 10 de configuraciones por porcentaje de audios que superan el umbral en **total agregado** (umbrales permisivo $\geq 10/20$ y estricto $\geq 12/20$).

C. Impacto social y medioambiental

Este capítulo analiza las implicaciones sociales y medioambientales del proyecto en el marco de los Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030 de las Naciones Unidas [onu2015agenda2030](#). La Tabla [C.1](#) recoge los cinco ODS más directamente relacionados con el trabajo.

Tabla C.1. Objetivos de Desarrollo Sostenible relacionados con el proyecto

ODS	Nombre	Relación con el proyecto
4	Educación de calidad	Herramientas para composición y aprendizaje musical asistido por IA
9	Industria e innovación	Contribución open-source a investigación en IA generativa creativa
10	Reducción de desigualdades	Democratización de la creación musical independiente de formación formal
12	Producción responsable	Uso de LoRA frente a fine-tuning completo: menor consumo por iteración
13	Acción por el clima	Cuantificación y contención del impacto energético del entrenamiento

C.1. Impacto social

C.1.1. ODS 4 – Educación de calidad

La música modal ha sido durante siglos un conocimiento reservado a músicos con formación teórica avanzada. Comprender la diferencia entre un modo dórico y un modo eólico, o elegir conscientemente un modo frigio para una composición flamenco, requiere habitualmente años de estudio armónico formal.

Este trabajo contribuye a reducir esa barrera al demostrar que un modelo generativo puede

aprender a producir música con carácter modal específico a partir de una indicación textual sencilla. En un escenario de aplicación, un estudiante de música o un compositor no académico podría indicar simplemente el modo objetivo —sin necesidad de conocer las escalas ni las notas características— y obtener una referencia sonora válida para explorar o aprender. Esto está alineado con la meta 4.4 del ODS 4, que propone aumentar el número de personas con acceso a competencias técnicas y creativas.

Adicionalmente, la metodología de evaluación dual desarrollada en este trabajo —con rúbrica musical explícita— puede ser reutilizada en contextos educativos para enseñar a evaluar musicalidad de forma estructurada, fomentando el pensamiento crítico sobre los resultados de sistemas generativos.

C.1.2. ODS 9 – Industria, innovación e infraestructura

El proyecto contribuye al ecosistema de investigación abierta en [IA](#) generativa creativa de varias formas. En primer lugar, la metodología experimental completa —incluyendo scripts de inferencia por lotes, pipeline de evaluación automática y protocolo de escucha informada— se publica junto al trabajo, permitiendo que otros investigadores o desarrolladores repliquen, extiendan o contrasten los resultados.

En segundo lugar, las correcciones técnicas realizadas sobre el código base de ACE-Step (sanitización del estado CUDA antes de inferencia, manejo defensivo de hooks en el DiT, soporte de LoKr) mejoran la robustez del proyecto para toda la comunidad de usuarios.

Esta apertura está alineada con la meta 9.5 del ODS 9, que promueve la innovación y el incremento del número de personas empleadas en investigación y desarrollo, favoreciendo el acceso abierto al conocimiento técnico.

C.1.3. ODS 10 – Reducción de las desigualdades

La producción musical profesional requiere acceso a instrumentos, estudios de grabación, músicos y conocimientos especializados, lo que la hace poco accesible para gran parte de la población. Los modelos generativos de música abiertos reducen parte de esta brecha al permitir crear contenido musical de calidad sin esos recursos.

El control modal que se desarrolla en este trabajo añade una capa adicional de expresividad:

no solo generar música, sino generar música con un carácter armónico específico. Esto amplía el potencial de estas herramientas para creadores de contenido audiovisual, compositores independientes, educadores musicales y personas con discapacidad física que no pueden acceder a instrumentos tradicionales.

Esta línea está relacionada con la meta 10.2 del ODS 10, que propone potenciar y promover la inclusión social, económica y política de todas las personas, incluidas las que tienen acceso limitado a recursos culturales o formativos.

C.2. Impacto medioambiental

C.2.1. ODS 12 – Producción y consumo responsables

El entrenamiento de modelos de inteligencia artificial de gran tamaño tiene un coste energético significativo. Una decisión central de diseño de este proyecto fue utilizar adaptadores LoRA en lugar de un fine-tuning completo del modelo base. Esta elección tiene consecuencias medioambientales directas:

- El número de parámetros entrenados en cada experimento es inferior al 1 % del total del modelo, lo que reduce el tiempo de cómputo por época y el consumo de memoria GPU.
- Al mantener el modelo base congelado, no es necesario almacenar ni transferir modelos completos entre iteraciones: solo los adaptadores, cuyo tamaño es del orden de megabytes frente a los gigabytes de un modelo completo.
- La selección temprana de checkpoints —en lugar de entrenar siempre hasta el máximo de epochs— evitó cómputo innecesario en configuraciones que mostraron sobreentrenamiento temprano.

Estas prácticas están alineadas con la meta 12.2 del ODS 12, que promueve la gestión sostenible y el uso eficiente de los recursos naturales, aplicado aquí al recurso energético consumido por la computación científica.

C.2.2. ODS 13 – Acción por el clima

Con el fin de cuantificar el impacto energético del proyecto, se estima el consumo total de GPU durante las fases de entrenamiento e inferencia. La Tabla C.2 recoge los bloques principales de trabajo y su duración aproximada.

Tabla C.2. Estimación del tiempo de uso de GPU durante el proyecto

Fase	Duración aprox.	Fuente
Búsqueda de hiperparámetros (24 experimentos $\times$ $\sim$ 90 min)	$\sim$ 36 h	CSV de resultados
run_D y experimentos exploratorios previos	$\sim$ 8 h	Estimación
Experimento de confirmación	$\sim$ 2 h	Estimación
Inferencia por lotes y evaluación automática	$\sim$ 6 h	Estimación
Total estimado	$\sim$52 h	

El servidor de entrenamiento utilizado dispone de una GPU NVIDIA GeForce RTX 3090 Ti, con una potencia térmica de diseño (TDP) de 480 W y 24 GB de memoria de vídeo. Durante las sesiones de entrenamiento la carga GPU ronda el 80 % del TDP; durante inferencia desciende al 50 %. Con estas estimaciones, el consumo energético total del proyecto se sitúa en el rango:

$$E \approx \underbrace{46 \text{ h} \times 384 \text{ W}}_{\text{entrenamiento (80 \% TDP)}} + \underbrace{6 \text{ h} \times 240 \text{ W}}_{\text{inferencia (50 \% TDP)}} \approx 19,1 \text{ kWh} \quad (\text{C.1})$$

Tomando el TDP máximo (480 W) como cota superior conservadora, el consumo máximo posible sería de $52 \times 0,48 \approx 25 \text{ kWh}$. A modo de referencia, un hogar medio español consume aproximadamente 3 500 kWh al año **idae2023consumo**, por lo que el impacto energético total del proyecto —entre 19 y 25 kWh— equivale a menos del 1 % del consumo doméstico anual. No obstante, el uso responsable de recursos computacionales en investigación es una práctica que debe consolidarse en la comunidad científica, especialmente a medida que los modelos de IA aumentan de tamaño.

Las decisiones metodológicas adoptadas en este trabajo —LoRA, evaluación escalonada y selección temprana de checkpoints— contribuyen a esta contención de forma activa, reduciendo el número de horas de cómputo necesarias respecto a un flujo de trabajo menos planificado. Esto está alineado con la meta 13.3 del ODS 13, que promueve la mejora de la educación y la concienciación sobre la mitigación del cambio climático, aplicada aquí al ámbito de la investigación computacional responsable.

Bibliografía

- [1] ACE-Step. *ACE-Step: A Step Towards Music Generation Foundation Model*. GitHub repository, 2025. Disponible en: <https://github.com/ace-step/ACE-Step>.
- [2] Jade Copet, Felix Kreuk, Itai Gat, Tal Remez, David Kant, Gabriel Synnaeve, Yossi Adi y Alexandre Défossez. *Simple and Controllable Music Generation*. NeurIPS, 2023.
- [3] Seth Forsgren y Hayk Martiros. *Riffusion - Stable diffusion for real-time music generation*. 2022. Disponible en: <https://riffusion.com/about>.
- [4] Suno. *Suno: Make any song you can imagine*. Sitio oficial, consultado en 2026. Disponible en: <https://suno.com/>.
- [5] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang y Weizhu Chen. *LoRA: Low-Rank Adaptation of Large Language Models*. ICLR, 2022.
- [6] Ning Ding, Yujia Qin, Guang Yang, Fuchao Wei, Zonghan Yang, Yusheng Su, Shengding Hu, Yulin Chen, Chi-Min Chan, Weize Chen, Jing Yi, Weilin Zhao, Xiaozhi Wang, Zhiyuan Liu, Hai-Tao Zheng, Jianfei Chen, Yang Liu, Jie Tang, Juanzi Li y Maosong Sun. *Parameter-Efficient Fine-Tuning of Large-Scale Pre-Trained Language Models*. *Nature Machine Intelligence*, 5:220–235, 2023.
- [7] Andrea Agostinelli, Timo I. Denk, Zalán Borsos, Jesse Engel, Mauro Verzetti, Antoine Cailion, Qingqing Huang, Aren Jansen, Adam Roberts, Marco Tagliasacchi, Matt Sharifi, Neil Zeghidour y Christian Frank. *MusicLM: Generating Music From Text*. arXiv:2301.11325, 2023.
- [8] Dongchao Yang, Jianwei Yu, Helin Wang, Wen Wang, Chao Weng, Yuexian Zou y Dong Yu. *DiffSound: Discrete Diffusion Model for Text-to-Sound Generation*. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 31:1720–1733, 2023.
- [9] Mark Levy y Mark Sandler. *Structural Segmentation of Musical Audio by Constrained Clustering*. *IEEE Transactions on Audio, Speech, and Language Processing*, 16(2):318–326, 2008.

- [10] George Tzanetakis y Perry Cook. *Musical Genre Classification of Audio Signals*. *IEEE Transactions on Speech and Audio Processing*, 10(5):293–302, 2002.
- [11] Udio. *Udio: Make your music*. Sitio oficial, consultado en 2026. Disponible en: <https://www.udio.com/>.
- [12] Naciones Unidas. *Transformar nuestro mundo: la Agenda 2030 para el Desarrollo Sostenible*. Resolución A/RES/70/1, 2015. Disponible en: <https://sdgs.un.org/goals>.
- [13] Instituto para la Diversificación y Ahorro de la Energía (IDAE). *Informe de Consumo Energético en los Hogares*. Ministerio para la Transición Ecológica y el Reto Demográfico, 2023. Disponible en: <https://www.idae.es>.
- [14] Carol L. Krumhansl y Edward J. Kessler. *Tracing the dynamic changes in perceived tonal organization in a spatial representation of musical keys*. *Psychological Review*, 89(4):334–368, 1982.
- [15] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel y Matt Le. *Flow Matching for Generative Modeling*. *ICLR*, 2023.
- [16] Jonathan Ho, Ajay Jain y Pieter Abbeel. *Denoising Diffusion Probabilistic Models*. *NeurIPS*, 2020.
- [17] William Peebles y Saining Xie. *Scalable Diffusion Models with Transformers*. *ICCV*, 2023.
- [18] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser e Illia Polosukhin. *Attention Is All You Need*. *NeurIPS*, 2017.
- [19] Zach Evans, Julian D. Parker, CJ Carr, Zack Zukowski, Josiah Taylor y Jordi Pons. *Stable Audio Open*. arXiv:2407.14358, 2024.
- [20] Haohe Liu, Zehua Chen, Yi Yuan, Xinhao Mei, Xubo Liu, Danilo Mandic, Wenwu Wang y Mark D. Plumbley. *AudioLDM: Text-to-Audio Generation with Latent Diffusion Models*. *ICML*, 2023.

Índice de términos

Glosario

ACE-Step Modelo generativo musical basado en una arquitectura híbrida para condicionamiento por texto y síntesis de audio [1](#), [5](#)

Siglas

IA inteligencia artificial [1](#), [59](#)

LoRA Low-Rank Adaptation [1](#), [2](#), [5](#), [7](#)

PFG proyecto de fin de grado [1](#), [3](#), [14](#)

